

بِسْمِ اللّٰهِ الرَّحْمٰنِ الرَّحِيْمِ



دانشکده مهندسی



دانشگاه فردوسی مشهد
دانشکده مهندسی - گروه کامپیوتر
آزمایشگاه بینایی ماشین

دانشگاه فردوسی مشهد

دانشکده مهندسی

گروه مهندسی کامپیوتر

پایان نامه برای دریافت درجه کارشناسی ارشد

هوش مصنوعی

تقسیم بندی تصاویر MRI مغزی

استاد راهنما: دکتر حمید رضا پور رضا

پژوهش و نگارش: مهدی صادقی بخی

مهرماه ۱۳۹۷



Ferdowsi University of Mashhad
m v l a b . u m . a c . i r

آزمایشگاه بینایی ماشین

تعهدنامه

اینجانب مهدی صادقی بخی دانشجوی کارشناسی ارشد رشته مهندسی کامپیوتر دانشکده مهندسی دانشگاه فردوسی مشهد نویسنده پایان نامه تقسیم بندی تصاویر MRI مغزی تحت راهنمایی دکتر حمید رضا پور رضامتعهد می شوم:

- تحقیقات در این پایان نامه توسط اینجانب انجام شده و از صحت و اصالت برخوردار است.
- در استفاده از نتایج پژوهشی محققان دیگر به مرجع مورد استفاده استناد شده است.
- مطالب مندرج در پایان نامه تاکنون توسط خود و یا فرد دیگری برای دریافت هیچ نوع مدرک یا امتیازی در هیچ جا ارائه نشده است.
- کلیه حقوق معنوی این اثر متعلق به دانشگاه فردوسی مشهد می باشد و مقالات مستخرج با نام "دانشگاه فردوسی مشهد" و یا "Ferdowsi University of Mashhad" به چاپ خواهد رسید.
- حقوق معنوی تمام افرادی که در به دست آمدن نتایج اصلی پایان نامه تاثیرگذار بوده اند در مقالات مستخرج از رساله رعایت شده است.
- در کلیه مراحل انجام این پایان نامه، در مواردی که از موجود زنده (یا بافت های آنها) استفاده شده است ضوابط و اصول اخلاقی رعایت شده است.
- در کلیه مراحل انجام این پایان نامه، در مواردی که به حوزه اطلاعات شخصی افراد دسترسی یافته یا استفاده شده است، اصل رازداری، ضوابط و اصول اخلاق انسانی رعایت شده است.

تاریخ
امضای دانشجو

مالکیت نتایج و حق نشر

- کلیه حقوق معنوی این اثر و محصولات آن (مقالات مستخرج، کتاب، برنامه های رایانه ای، نرم افزارها و تجهیزات ساخته شده) متعلق به دانشگاه فردوسی مشهد می باشد. این مطلب باید به نحو مقتضی در تولیدات علمی مربوطه ذکر شود.
- استفاده از اطلاعات و نتایج موجود در پایان نامه بدون ذکر مرجع مجاز نمی باشد.

تقدیم به

پدر و مادر عزیزم

و همه کسانی که درست اندیشیدن را به من آموختند.

سپاس‌گزاری

سپاس خداوند یکتای عزتمندی که رحمت و دانش او در سراسر گیتی گسترده شده، آسمان‌ها و زمین همه از آن اوست و علم و دانش حقیقی را برابر هر که بخواهد موهبت می‌فرماید. رحمت و لطف او را بیننهایت سپاس می‌گوییم چرا که فهم و درک مطالب این پژوهش را برابر من ارزانی داشت و مرا به این اصل رساند که علم و ایمان دو بال یک پروازند. توفیق تلاش به من داد و هر بار که خطا کردم فرصتی دوباره، تا با امید، تلاشی تازه را آغاز کنم و به خواست او به نتیجه‌ی مطلوب نائل آیم. به راستی که همه چیز از آن اوست و همه‌چیز به خواست اوست.

بسمه تعالیٰ

شناسه: ب/ک/3	<p>صورتجلسه دفاعیه پایان نامه دانشجوی دوره کارشناسی ارشد</p> <p>دانشجوی کارشناسی ارشد</p>	 <p>دانشگاه فنی شهرورد مدیریت تحصیلات تكمیلی</p>
و درجه	پس از ارزیابی توسط هیأت داوران، پایان نامه با نمره به عدد به حروف	جلسه دفاعیه پایان نامه تحصیلی آقای/ خانم: مهدی صادقی بخی رشته/ گرایش: مهندسی کامپیوتر/ هوش مصنوعی تحت عنوان: تقسیم بندی تصاویر MRI مغزی و تعداد واحد: ۶ در تاریخ ۱۳۹۷/۰۷/۳۰ با حضور اعضای هیأت داوران (به شرح ذیل) تشکیل گردید.
<u>امضاء</u>	<u>نام و نام خانوادگی</u>	<u>عنوان</u>
	دکتر حمید رضا پور رضا	استاد/ استادان راهنمای:
		استاد/ استادان مشاور:
	دکتر	متخصص و صاحب نظر داخلی:
		متخصص و صاحب نظر خارجی:
	نامینده تحصیلات تكمیلی دانشگاه (ناظر)	
	نام و نام خانوادگی:	
	امضاء:	

چکیده

MS یک بیماری خودایمنی سیستم عصبی مرکزی است که موجب آسیب به عایق غلاف میلین در اطراف آکسون مغز می‌شود. این بیماری بیش از ۲/۵ میلیون نفر در سراسر جهان را تحت تأثیر قرار داده است. وجود روشی سریع و دقیق برای ارزیابی اندازه و تعداد ضایعات MS در مغز، یک جزء کلیدی در ارزیابی پیشرفت این بیماری و اثربخشی دوره‌های درمانی است. تقسیم‌بندی ضایعه‌ی MS به صورت دستی معمولاً به یک متخصص آموزش دیده نیاز دارد و بسیار کند و دشوار بوده و نتایج آن تا حدودی ذهنی است. از این‌رو وجود سیستمی خودکار جهت استخراج ضایعات امری ضروری است. با اینکه روش‌های خودکار بسیاری ارائه شده است، اما نتایج تقسیم‌بندی به اندازه‌ی کافی دقیق نمی‌باشند. در نتیجه نیاز فراوانی به ایجاد یک روش قوی، سریع و دقیق برای بخش‌بندی خودکار ضایعات MS وجود دارد.

فهرست مطالب

ت

فهرست جداول

ث

فهرست تصاویر

ج

فهرست نمادها

۱

۱ مقدمه

۲

۱-۱ مقدمه

۲

۱-۱-۱ دلائل بیماری

۳

۲-۱-۱ شیوع MS

۳

۳-۱-۱ علائم بالینی بیماری

۴

۲-۱ شرح مساله

۵

۳-۱ بافت مغز

۵

۱-۳-۱ ماده سفید

۶

۲-۳-۱ ماده خاکستری

۶

۳-۳-۱ مایع مغزی نخاعی

۷

۴-۱ تصویر برداری تشدید مغناطیسی

۸

۱-۴-۱ تصویر T1-Weighted

۸

۲-۴-۱ تصویر T2-Weighted

۹

۳-۴-۱ تصویر PD-Weighted

۹	۴-۴-۱ تصاویر FLAIR
۱۰	۵-۱ روش تشخیص بیماری MS
۱۲	۶-۱ نتیجه‌گیری
۱۳		۲ مروری بر کارهای گذشته
۱۴	۱-۲ مقدمه
۱۴	۲-۲ مفاهیم اساسی
۱۴	۱-۲-۲ تصاویر دو بعدی و سه بعدی
۱۵	۲-۲-۲ مفهوم قطعه‌بندی تصویر
۱۶	۳-۲-۲ ویژگی تصاویر
۱۷	۳-۲ پیش‌پردازش تصاویر MRI
۱۸	۱-۳-۲ حذف میدان بایاس
۲۶	۲-۳-۲ تطبیق تصاویر
۲۷	۳-۳-۲ حذف بافت غیر مغز
۲۸	۴-۲ روش‌های قطعه‌بندی تصاویر MRI
۲۹	۱-۴-۲ تقسیم بندی دستی
۳۰	۲-۴-۲ روش‌های مبتنی بر شدت
۴۳	۳-۴-۲ روش‌های مبتنی بر اطلس
۴۷	۴-۴-۲ روش‌های مبتنی بر رویه
۵۴	۵-۴-۲ روش‌های تقسیم بندی ترکیبی
۵۸	۵-۲ جمع‌بندی
۵۹		منابع و مأخذ

فهرست جداول

۱۰	۱-۱ مقایسه انواع تصاویر [۱] MRI
۴۴	۱-۲ مزایا و معایب روش‌های مبتنی بر شدت
۴۷	۲-۲ مزایا و معایب روش‌های مبتنی بر اطلس
۵۴	۳-۲ مزایا و معایب روش‌های مبتنی رویه

فهرست تصاویر

۱-۱	نمایش یک نرون [۲]	۳
۲-۱	تصویر MRI مربوط به فرد مبتلا به بیماری ام اس	۴
۳-۱	بافت مغز [۳]	۵
۴-۱	مایع مغزی نخاعی [۴]	۷
۵-۱	مقایسه انواع تصاویر MRI [۵]	۹
۶-۱	نمایش پلاکهای بیماری MS در انواع تصاویر MRI [۶]	۱۱
۱-۲	تصویری از عناصر تصویر در MRI مغز [۷]	۱۵
۲-۲	نمایش عناصر تصاویر در فضای دو بعدی و سه بعدی [۷]	۱۶
۳-۲	نمونه‌ای از یک تصویر MRI [۷]	۱۶
۴-۲	مراحل پیش‌پردازش [۷]	۱۷
۵-۲	نمونه‌ای از حذف میدان بایاس از تصویر [۸]	۱۸
۶-۲	روش‌های حذف میدان بایاس [۹]	۲۰
۷-۲	نتایج حاصل از پیاده سازی روش [۱۰]	۲۷
۸-۲	نمونه‌ای از حذف بافت غیر مغز [۷]	۲۸
۹-۲	دسته‌بندی روش‌های تقسیم‌بندی MRI [۷]	۲۹
۱۰-۲	تقسیم‌بندی مبتنی بر آستانه گذاری	۳۱
۱۱-۲	شبکه‌های کانولوشنی استفاده شده در [۱۱]	۳۴
۱۲-۲	فلوچارت روش پیشنهادی [۱۲]	۳۵

۳۷	۱۳-۲ معماری پیشنهادی مقاله [۱۳]
۴۰	۱۴-۲ مدل ارایه شده برای پیش آموزش [۱۳]
۴۵	۱۵-۲ فلوچارت روش‌های مبتنی بر اطلس [۵]
۴۵	۱۶-۲ فلوچارت روش پیشنهادی [۱۴]
۴۹	۱۷-۲ فلوچارت روش پیشنهادی [۱۵]
۵۵	۱۸-۲ فلوچارت روش پیشنهادی [۱۶]

فهرست نمادها

فصل ۱

مقدمه

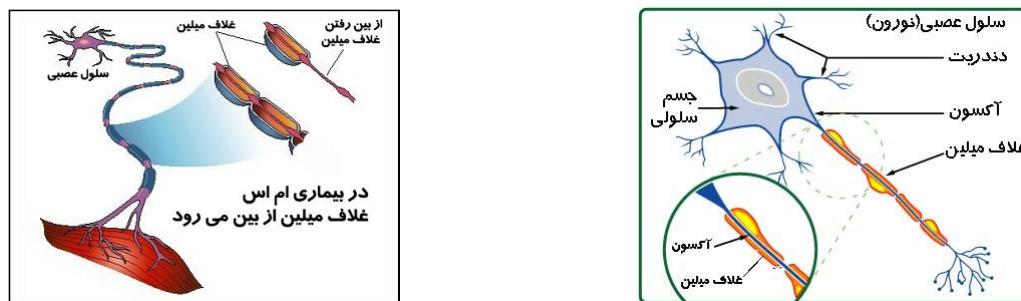
۱-۱ مقدمه

MS از بیماری‌های شایع سیستم عصبی مرکزی در انسان و یک بیماری خود ایمنی است. این بیماری به صورت مزمن خود را نشان می‌دهد. اغلب، بالغین جوان را مبتلا می‌سازد و در جنس مؤنث دو تا سه برابر بیشتر رخ می‌دهد. در MS میلیون راههای عصبی دچار تخریب می‌شود. مشخصه این بیماری، متعدد بودن ضایعات از نظر زمانی و مکانی و رخداد علائم به صورت رفت و برگشتی است. یعنی یک علامت عصبی پس از مدتی بهبود یافته و در زمان دیگر همان علامت یا علائم دیگری مجدداً رخ می‌دهند. علائم هر حمله بهبودی نسبی یافته، ولی ممکن است عودهای مکرر بیماری سبب ناتوانی تدریجی بیمار گردد. در MS علائم بالینی بستگی به محل و وسعت ضایعه دارد و تخریب میلیون معمولاً در نواحی خاصی نظیر عصب بینایی، ساقه مغز، مخچه و ماده سفید نیم‌کره‌های مغز منجر به بروز مجموعه‌ای از علائم بالینی به صورت تاری دید ناگهانی، ناتوانی در حرکت اندام‌ها، عدم تعادل، دوبینی و اختلالات حسی به صورت احساس خواب رفتگی در اندام‌ها و علائم متنوع دیگر می‌گردد. سیر علائم بالینی بیماری MS در هر بیماری متفاوت بوده و می‌تواند به صورت یک بیماری کاملاً خوش‌خیم رخ دهد و بیمار سال‌ها عاری از علائم عصبی باشد و یا این‌که یک حالت پیشرونده سریع در علائم بالینی همراه با ناتوانی اتفاق می‌افتد.^[۳].

۱-۱-۱ دلائل بیماری

هنوز علت این بیماری مهلك شناخته نشده است. محققان معتقدند که شاید عوامل ارثی، تغذیه‌ای و محیطی در آن دخیل باشند. اما نظریه‌هایی برای پیدایش MS ارائه شده است. قابل قبول‌ترین تئوری در مورد علت بیماری MS را یک مکانیسم خود ایمنی می‌دانند، به این نحو که یک فاکتور محیطی نظیر عفونت‌های ویروسی سبب تحریک سیستم ایمنی بدن و تشکیل آنتی‌بادی بر علیه میلین بافت عصبی شده، در نتیجه میلین اعصاب از بین رفته و منجر به بروز علائم عصبی می‌شود. فاکتورهای ژنتیکی در مستعد نمودن فرد جهت ابتلا به این بیماری می‌توانند مؤثر باشند. بالاترین شیوع MS در نژاد سفید پوست می‌باشد و این بیماری در نژاد زرد و سیاه شیوع کمتری دارد. این بیماری در ساکنین مناطق اطراف ناحیه استوا بندرت دیده می‌شود، در حالی که با افزایش فاصله از خط استوا و در مناطق معتدل‌هشتم شمالی و جنوبی، نظیر آمریکا، کانادا، اروپای شمالی و استرالیا، شیوع این بیماری بیشتر می‌شود. مهاجرت به مناطق با شیوع کم قبل از ۱۵ سالگی خطر ابتلا به بیماری MS را کاهش می‌دهد. افرادی که در نیم‌کره شمالی کره زمین در ماه اردیبهشت به دنیا می‌آیند با احتمال بیشتری به بیماری مولتیپل اسکلروز مبتلا می‌شوند. دانشمندان نتوانسته‌اند ارتباط بین MS و ماه تولد را شرح دهند ولی اینطور تصور می‌نمایند که این نتایج می‌تواند با تابش خورشید و مقدار ویتامین D مادر که

رشد جنین را تحت تاثیر قرار می‌دهد مرتبط باشد. چون در نیم کره شمالی در این ماه مقدار تابش خورشید کم است و مقدار کمی از ویتامین D در بدن افراد ساخته می‌شود.



(ب) تاثیر بیماری MS بر روی نرون
شکل ۱-۱: نمایش یک نرون [۲]

(ا) نمایش یک نرون از مغز سالم

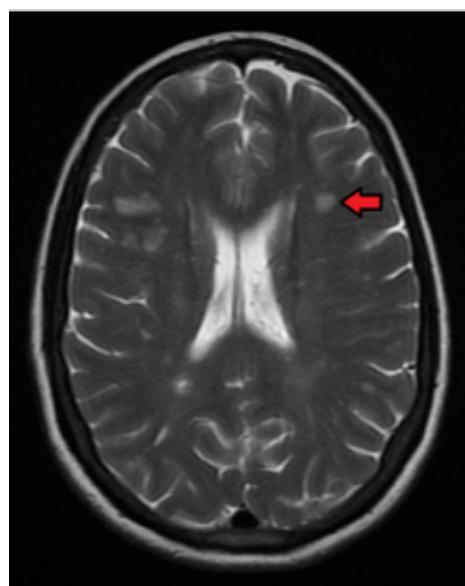
۲-۱-۱ شیوع MS

وقوع MS در دوران کودکی نادر است، اما بعداً به سرعت شیوع آن افزایش می‌یابد تا در حوالی ۳۰ سالگی به حداقل می‌رسد و همچنان شیوع آن تا دهه چهارم عمر بالا می‌ماند و سپس سریعاً کاهش می‌یابد به طوری که MS پس از ۶۰ سال، به ندرت رخ می‌دهد. به دلیل فاکتورهای هورمونی و سیستم ایمنی بروز بیماری MS در زنان دو تا سه برابر مردان است. عموماً MS در طبقات اجتماعی-اقتصادی بالا بیشتر دیده می‌شود.

۳-۱-۱ علائم بالینی بیماری

در ابتدا بیمار تقریباً هیچ‌گونه علائم پزشکی ندارد، اما پس از گذشت چند سال، بیماری بروز می‌کند. علائم عصبی در بیماری MS به دلیل درگیری قسمت‌های مختلف دستگاه عصبی مرکزی متعدد می‌باشد. به دلیل ماهیت بیماری و درگیری قسمت‌های مختلف سیستم عصبی و نیز دخالت عوامل جغرافیایی در چگونگی تظاهر بیماری، علائم و بهویژه اولین علامت شروع بیماری متعدد و شدت آن نیز متغیر خواهد بود، بنابراین در بیماری MS هیچ‌گاه یک فرم کلاسیک و ثابت و مشخص نمی‌توان یافت. چون در MS عصب بینایی، ساقه مغز، مخچه و نخاع بیشتر درگیر می‌شوند، شایع‌ترین علائم در شروع بیماری عبارتند از: ضعف دستگاه حرکتی، احساس درد سوزنی، اختلال در دید، کاهش یا تاری دید ناگهانی در یک چشم، دوبینی، حرکت غیرارادی چشم، اختلال در فهم کلمات،

لرزش، اختلال در حس‌های عمقی و از دست دادن تعادل، فلج قسمتی از اندام تحتانی و تغییر در پاسخ‌های عاطفی، احساس گرفتگی و گزگز یا عدم تعادل یک اندام، اختلال عملکرد مثانه به صورت فوریت یا تأخیر در شروع ادرار. این علائم غالباً گذرا بوده و طی چند روز تا چند هفته از بین می‌روند، ولی با گذشت زمان این علائم ممکن است مستقر و ثابت شده و بیمار گاهی دچار مشکلات گفتاری، شناختی و خلقی و حافظه‌ای می‌گردد. پیشرفت حاد و سریع در این بیماری به ندرت دیده می‌شود و در بیشتر مبتلایان سیر بیماری خوش خیم بوده و علائم آن قدر خفیف هستند که حتی به پزشک هم مراجعه نمی‌کنند.



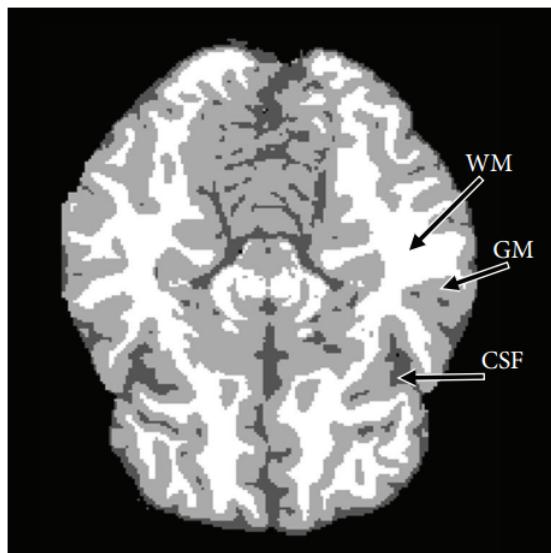
شکل ۱-۲: تصویر MRI مربوط به فرد مبتلا به بیماری ام اس

۲-۱ شرح مساله

نوعی بیماری التهابی مزمن، ناتوان کننده و اغلب پیشرونده در سیستم اعصاب مرکزی است که منجر به از بین رفتن پوشش میلین تارهای عصبی می‌شود و به تدریج می‌تواند باعث اختلال در انتقال پیام‌های عصبی بین مغز و سایر قسمت‌های بدن شود. نهایتاً چنین شرایطی منجر به تحلیل غیرقابل برگشت اعصاب می‌گردد. یکی از روش‌های تشخیص این بیماری استفاده از تصویر برداری با شدید مغناطیسی یا همان MRI می‌باشد. یک پزشک متخصص علاوه بر تصویر MRI نیاز به یکسری آزمایش‌های دیگری نظیر معاینه‌ی عصبی و معاینه چشم می‌باشد که این در این صورت روند تشخیص هزینه‌بر و کند می‌باشد. در این تحقیق سعی بر این می‌باشد تا با استفاده از روش‌های هوش‌مصنوعی بتوان پلاک‌های بیماری MS را در تصاویر MRI تشخیص داد و به عنوان یک دستیار بتواند مورد استفاده پزشک متخصص قرار گیرد.

۳-۱ بافت مغز

مغز انسان مرکز دستگاه عصبی است. دستگاه عصبی مرکزی در درون حفاظی استخوانی به نام جمجمه و ستون فقرات قرار گرفته و شامل مغز و نخاع می‌باشد. سیستم اعصاب مرکزی در زبان عام به دو قسمت با نام‌های ماده سفید و ماده خاکستری تقسیم می‌شود و همچنین این سیستم در مایعی به نام CSF^۱ یا همان مایع مغزی نخاعی، شناور است. تصویر ۱-۳ نمایش انواع بافت مغز می‌باشد که هر یک از این ماده‌ها در ادامه به تفضیل شرح داده خواهد شد [۳].



شکل ۱-۳: بافت مغز [۳]

۱-۳-۱ ماده سفید

ماده سفید شامل بسته‌های نرم افزاری است که مناطق مختلف خاکستری مغز را به یکدیگر متصل می‌کند و ضربان عصبی بین نورون‌ها را حمل می‌کند که ماده سفید دارای میلین زیادی است. میلین به عنوان یک عایق عمل می‌کند که به سیگنال‌های الکتریکی برای پریدن اجازه می‌دهد نه از طریق حرکت آکسون و به این ترتیب سرعت انتقال تمام سیگنال‌های عصبی را افزایش می‌دهد. این ماده به نواحی سیستم عصبی مرکزی اشاره دارد که عمدتاً از آکسون‌های میلین دار تشکیل شده است. تحقیق‌ها اینطور نشان داده که بافتهای غیر فعال ماده سفید تاثیرات یادگیری بر مغز را تحت تاثیر قرار می‌دهد و به عنوان یک ارتباط دهنده و هماهنگ کننده بین مناطق مختلف مغز می‌باشد. [۴]

^۱Cerebrospinal Fluid

۲-۳-۱ ماده خاکستری

این ماده شامل تجمع جسم سلولی نورون‌ها و الیاف عصبی بدون میلین است که در دو ناحیه قرار دارد.

● قشر مخ: قسمت اعظم این ماده (ماده خاکستری) در محیط مغز قرار گرفته است. رشد این قسمت که مرکز بیشتر فعالیت‌های

بدن می‌باشد، در انسان از حیوانات بیشتر است به همین دلیل انسان از قدرت تفکر، خلاقیت و تکلم بالاتری برخوردار است.

باتوجه به رشد زیاد قشر مخ، جمجمه نمی‌تواند همه آن را در خود جای دهد بنابراین چین‌خوردگی‌هایی پیدا می‌کند.

● هسته‌ها: بخشی از ماده خاکستری داخل هسته‌های مغز قرار می‌گیرند. که این هسته‌ها در داخل ماده سفید مغز وجود دارند.

در تصاویر MRI که در آینده معرفی می‌شوند این هسته‌ها قابل مشاهده نمی‌باشد.

۳-۳-۱ مایع مغزی نخاعی

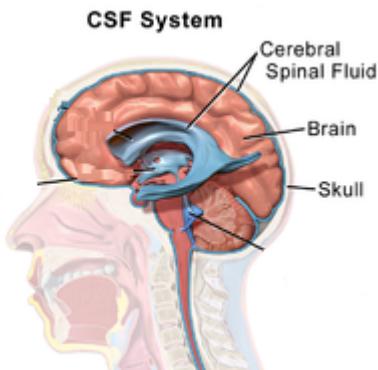
csf یا همان مایع مغزی نخاعی مایع روشن بی رنگ است شبیه پلاسمای خون در شبکه‌های کوروئید^۱ بطن مغز ترشح می‌شود که مغز و نخاع را پر می‌کند. یک مانع مکانیکی در برابر شوک می‌باشد به طور عمده در بطن مغز تشکیل می‌شود. مایع مغزی نخاعی از مغز پشتیبانی می‌کند و روان‌کاری بین استخوان‌های اطراف مغز و نخاع را فراهم می‌کند. هنگامی که یک فرد دچار آسیب سر شود این سیال به عنوان یک ضربه‌گیر^۲ عمل می‌کند و با توزیع نیروی وارد شده به کل مغز باعث کاهش اثر نیرو بر مغز می‌شود تا فشار در داخل مغز در یک سطح ثابت حفظ شود.

افزایش حجم خون یا بافت مغزی باعث کاهش مایع می‌شود و اگر مقدار ماده در داخل جمجمه کاهش یابد همانطور که در آتروفی مغز (کوچک شدن مغز) اتفاق می‌افتد، csf با افزایش حجم این مشکل را جبران می‌کند. همچنین این مایع مواد زائد مغز را دفع می‌کند. این مایع خاصیت بازی دارد و حدود ۹۹ درصد آن را آب تشکیل می‌دهد. مایع مغزی نخاعی در تصویر ۴-۱ به شکل آبی رنگ قابل مشاهده می‌باشد.

بدن انسان به طور عمده از آب و استخوان تشکیل شده است. علاوه بر این، عناصر کمیاب در نقاط مختلف بدن انسان مانند ید در تیروئید، تلوریوم در کبد و آهن در خون وجود دارد. تکنیک‌های تصویربرداری پزشکی از خواص مختلف این عناصر استفاده

^۱Coroid

^۲cushion



شکل ۱-۴: مایع مغزی نخاعی [۴]

می‌کنند.^[۱۷] روش‌های مهم عبارتند از: اشعه ایکس^۱، توموگرافی رایانه‌ای^۲، توموگرافی انتشار پوزیترون^۳، الکتروانسفالوگرافی^۴ و تصویر برداری تشdiid مغناطیسی^۵. از آنجایی که هدف این تحقیق تشخیص پلاک‌های MS از روی تصاویر MRI می‌باشد بنابراین در ادامه به توضیح این روش تصویر برداری پرداخته خواهد شد.

۴-۱ تصویر برداری تشdiid مغناطیسی

MRI یکی از تکنولوژی‌هایی می‌باشد که در زمینه تصویر برداری پزشکی در سال‌های اخیر پیشرفت چشم‌گیری در کیفیت و سرعت تصویر برداری ایجاد کرده است. امواج مورد استفاده در MRI از جنس امواج رادیویی و مغناطیسی می‌باشند که ضرری برای بدن ندارند. در این روش تصویر برداری بیمار در یک میدان مغناطیسی بسیار قوی قرار می‌گیرد بنابراین باعث می‌شود محور چرخش پروتون اتم‌ها در تمام بافت‌های بدن (بخصوص پروتون‌های موجود در هسته مولکول آب) در امتداد خطوط میدان مغناطیسی قرار گیرند. سپس امواج رادیویی خاصی به سوی بدن بیمار تابانده می‌شود. از آنجایی که این امواج که بصورت پالس ارسال می‌شوند باعث تغییر محور چرخش پروتون‌ها می‌شود. پس اتمام پالس رادیویی، محور چرخش پروتون مجدداً در امتداد خطوط میدان مغناطیس قرار می‌گیرند. این برگشت موجب ایجاد یک موج الکترومغناطیسی جدید می‌شود. سپس این امواج جدید که از تک پروتون‌ها ساطع می‌شوند توسط گیرندهای دستگاه MRI دریافت می‌شوند و به یارانه آن ارسال می‌شود. امواج دریافت شده تحلیل شده و سپس تصاویری براساس این تحلیل‌ها ایجاد می‌شود. در کامپیوتر تصویر MRI مشخص می‌شود که چه نقاطی از بدن موج رادیویی بیشتری از خود ساطع کرده‌اند. هرچه شدت موج دریافتی بیشتر باشد نشانه‌ی تراکم بیشتر پروتون در آن نقطه است و

^۱X-ray

^۲CT

^۳PET

^۴Electroencephalography (EEG)

^۵Magnetic resonance imaging

چون فراوان ترین اتم بدن اتم هیدروژنی است که در مولکول آب قرار دارد پس هرجایی که موج رادیویی بیشتری ارسال شده است در واقع آب بیشتری در آن نقطه وجود داشته است [۱۸].

قدرت سیگنالی که در MRI به وجود می‌آید به دو عامل چگالی پروتون‌ها و زمان‌های استراحت T1 و T2 بستگی دارد. T1 مدت زمانی است که ۶۳ میان مغناطیسی طولی یک پروتون پس از برانگیختگی، از راستای عمود بر میدان به راستای موازات میدان مغناطیسی باز می‌گردد. همچنین T2 مدت زمانی است که میان مغناطیسی عرضی یک پروتون پس از برانگیختگی، به ۳۷ مقدار اولیه خود تنزل می‌یابد. در هر بافتی این مدت زمان متفاوت است. به طور مثال در شدت میدان ۱.۵ تسلا ثابت T1 برای بافت چربی ۲۶۰ میلی ثانیه و برای بافت ماده خاکستری مغز ۹۲۰ میلی ثانیه می‌باشد. اکثر فرایندهای پاتولوژیک، موجب افزایش زمان استراحت^۱ T1 و آن‌ها می‌شوند و لذا در مقایسه با بافتهای طبیعی اطراف، در تصاویر T1-weighted سیگنال پایین‌تر (تیره رنگتر) و در تصاویر T2-weighted سیگنال بالاتر (روشن‌تر) خواهند داشت [۱۸].

سیستم‌های MRI اصولاً دارای شدت میدان‌های ۰.۲، ۱ و ۳ تسلا می‌باشند. در برخی از کشورها بیمارستان‌ها و مراکز خدمات بهداشتی اجازه استفاده از سیستم‌ها تا ۴ تسلا را نیز برای یک بیمار دارند. اما از ۴ تسلا به بالا صرفاً جنبه و کاربردهای تحقیقاتی دارد [۱۸].

تکنیک‌های رایجی که برای بررسی بیماری MS استفاده می‌شوند، عبارتند از: تصاویر T1-W، T2-W، PD-W و تصاویر FLAIR که در ادامه به تفضیل شرح داده می‌شوند [۱۹].

۱-۴-۱ تصاویر T1-Weighted

این یک روش پایه در اسکن MRI می‌باشد، برای مثال، در این روش تصویر سازی، تفاوت دو بافت چربی و آب، به صورت تیره‌تر بودن آب نسبت به بافت چربی می‌باشد.

۲-۴-۱ تصاویر T2-Weighted

این روش نیز یکی از روش‌های اصلی تصویرسازی MRI می‌باشد. در این روش مانند T1-Weighted چربی و آب قابل تفکیک بوده با این تفاوت که چربی تیره تر و آب روش‌تر در تصویر ظاهر می‌گردد. برای مثال در مطالعه‌ی مغز و ستون فقرات، مایع مغزی

^۱Relaxation time

نخاعی به صورت روشن تر در تصویر ظاهر می‌گردد.

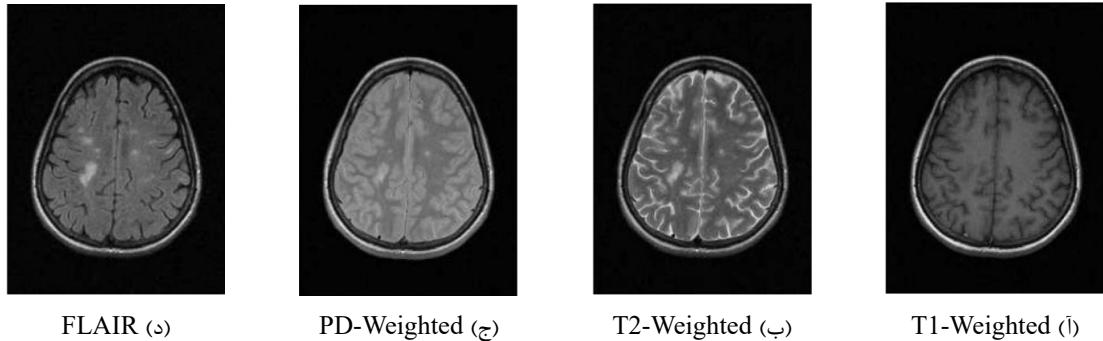
در این تصاویر ضایعات MS بالاترین شدت روشناهی را در تصویر دارند چرا که میزان آب موجود در ضایعات زیادتر از سایر بافت مغز می‌باشد.

۳-۴-۱ تصاویر PD-Weighted

این روش به نام چگالی پروتون نیز شناخته می‌شود. کنتراست در تصاویر حاصل از این روش تصویر سازی، وابسته به مقادیر T1 و T2 نبوده و تنها به اختلاف چگالی اسپین‌های اتم هیدروژن موجود در بافت‌ها وابسته می‌باشد.

۴-۴-۱ تصاویر FLAIR

این روش قابلیت نمایش مناسب ضایعات کوچک را دارد. در این تصویر سیگنال ارسالی از مایعات مانند CSF برابر با صفر در نظر گرفته می‌شود. بنابراین در این تصویر اختلالات نزدیک به خوبی قابل مشاهده هستند.



شکل ۱-۵: مقایسه انواع تصاویر MRI [۵]

همچنین به علت نحوه تشکیل انواع تصاویر، کنتراست بالایی بین بافت اصلی مغز، قسمت خاکستری، قسمت سفید و مایع CSF وجود دارد. قسمت CSF در تصاویر T1 و FLAIR به صورت تیره ظاهر می‌شود در حالی که در تصاویر T2 به صورت روشن تر دیده می‌شود و در تصاویر PD با بخش خاکستری شدت روشناهی یکسانی دارد. قسمت سفید مغز در تصاویر T1 روشن‌ترین قسمت، در تصاویر PD و T2 کمترین شدت روشناهی و در تصاویر FLAIR شدت روشناهی تقریباً یکسانی با قسمت خاکستری مغز دارد. در نهایت قسمت خاکستری مغز، در تصاویر T1 و T2 شدت روشناهی متوجه دارد. هر تصویر دارای مزایا و معایبی است به طور مثال تصاویر T1 برای بررسی آناتومی بافت مناسب هستند در حالی که چون ضایعات نسبت به حالت معمول دارای مایعات بیشتری

هستند در تصاویر T2 و FLAIR شدت روشنایی بالاتری دارند و بهتر قابل تشخیص هستند. تصاویر PD نیز برای مطالعه‌ی آناتومی و همچنین ضایعات مناسب هستند. جدول ۱-۱ مقایسه‌ی انواع تصاویر MRI می‌باشد.

جدول ۱-۱: مقایسه‌ی انواع تصاویر MRI [۱]

	T1-W
۱. ضایعه MS با شدت روشنایی پایین ظاهر می‌شود. ۲. مناسب برای تطبیق دادن ۳. تصویر آناتومیکی مغز	
۱. ضایعه MS با شدت روشنایی بالا ظاهر می‌شود. ۲. بافت‌های CSF، GM با ضایعه MS شدت روشنایی نزدیک دارند. ۳. در این تصویر ضایعات MS نسبت به تصویر PD-W بهتر برجسته می‌شوند.	T2-W
۱. ضایعه MS با شدت روشنایی بالا ظاهر می‌شود. ۲. بافت CSF با ضایعه MS شدت روشنایی نزدیک دارند و به راحتی قابل جدا کردن نمی‌باشند.	PD-W
۱. ضایعه MS با شدت روشنایی بالا ظاهر می‌شود. ۲. بافت CSF با ضایعه MS قابل جدا کردن می‌باشند. ۳. ضایعات MS که در مغز و مخچه قرار دارند، دشوار است قابل تشخیص باشند.	FLAIR

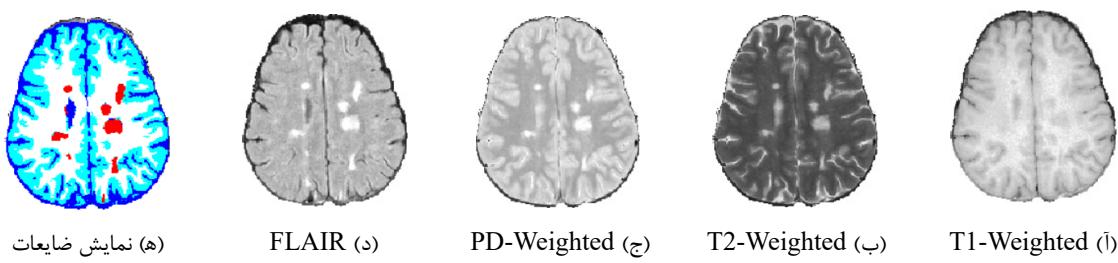
۵-۱ روش تشخیص بیماری MS

بیماری MS خود را در MRI به شکل کانون‌های کوچک گرد یا بیضوی متعدد در ماده سفید مغز نشان می‌دهد که اصطلاحاً به آنها "پلاک" می‌گویند و هر روزه در MRI مغز افراد مختلف با یا بدون علامت بالینی خاصی که MRI مغز می‌گیرند این کانون‌های کوچک ملاحظه می‌شود که شبیه به یافته‌های MS می‌باشد و گزارش آن‌ها توسط رادیولوژیست‌ها گاهی باعث نگرانی در بیماران، خانواده آن‌ها و پزشکان معالج می‌شود. واقعیت این است که تشخیص اصلی MS با معاینات بالینی و توسط متخصصین مغز و اعصاب باستی داده شود و نه MRI و نقش کمک کننده برای تأیید یا رد این تشخیص را دارد به طوری که اگر قرار باشد تنها بر

اساس یافته‌های MRI بخواهیم MS را تشخیص بدھیم (بدون توجه به علائم بالینی بیماران) MRI تنها در ۱۱ درصد موارد قادر به تشخیص این بیماری است و در واقع در ۸۹ درصد موارد MRI قادر به تشخیص نیست، لذا پاسخ سوال فوق منفی است و گروه وسیعی از بیماری‌های مختلف از ضایعات ایسکمی و عfonی گرفته تا ترومما، سندروم‌های خاص و حتی بیماری‌های متابولیک قادرند کانون‌های کوچک متعددی را در مغز ایجاد نمایند که شبیه به MS باشند که در اصطلاح به این‌ها "تقلید کننده‌های MS" گفته می‌شود و همانطوری که اشاره شد این گروه آنقدر طیف وسیعی دارند که در صورت عدم اطلاع پزشک متخصصین مغز و اعصاب و یا متخصصین نورادیولوژی از آن‌ها گاهی می‌تواند به عنوان MS در MRI تفسیر شده و حتی بیماران تحت درمان غیر ضروری قرار گرفته و ناخواسته مارک بیماری MS به افراد زده شود که موارد زیادی از آن‌ها را تاکنون داشته‌ایم.

معیار مطرح شده مک دونالد، که شامل ترکیبی از علائم بالینی و ویژگی‌های MRI می‌باشد برای تشخیص MS مطرح شده‌اند. بر طبق این طرح، MS می‌تواند بعد از یک دوره معاینه پزشکی و زمانی که نواحی MS در تصاویر MRI واضح‌اند، تشخیص داده شوند. تصویربرداری MR ثابت کرده است که نسبت به بیماری MS خیلی حساس می‌باشد، زیرا نواحی که پوشش می‌لین خود را از دست داده‌اند نسبت به بافت‌های محیطی خود می‌توانند با شدت متفاوتی ظاهر شوند. تصویربرداری به روش T1 اغلب ضایعات را به صورت نواحی با شدت پایین نشان می‌دهد. بهترین روش برای نشان دادن تغییرات خاص MS، استفاده از تصویربرداری به روش T2 می‌باشد که در آن نواحی غیر طبیعی به صورت شدت بالا ظاهر می‌شوند و از ماده مغزی مجاور متمایز می‌شوند. تصاویر T2 نیز همچون تصاویر T1، ضایعات را به صورت نواحی روشن نشان می‌دهند [۶].

از دیگر ویژگی‌های مورد استفاده در تشخیص پلاک‌های بیماری MS محل وقوع این بیماری می‌باشد. پلاک‌های بیماری MS در بافت WM و یا بین بافت GM اتفاق می‌افتد. شکل ۱-۶ نمایش پلاک‌های این بیماری در انواع روش‌های تصویربرداری MRI را نشان می‌دهد.



شکل ۱-۶: نمایش پلاک‌های بیماری MS در انواع تصاویر MRI [۶]

۶-۱ نتیجه‌گیری

در این فصل به معرفی بیماری MS و علایم آن و همچنین انواع روش‌های تصویر برداری مغز پرداخته شد و در نهایت بیان مساله شرح داده شد و چالش‌های آن مورد بررسی قرار گرفت. در فصل بعد مرواری بر روش‌های تشخیص پلاک‌های بیماری MS خواهیم پرداخت و انواع روش‌های موجود را مورد بررسی قرار خواهیم داد.

فصل ۲

مروری بر کارهای گذشته

۱-۲ مقدمه

تقسیم‌بندی جراحات بیماری MS به صورت خودکار در تصاویر MRI به منظور کاهش خطاهای انسانی و کاهش حجم کار امری ضروری است. در طول دهه‌های اخیر مطالعات و روش‌های بسیاری برای حل این مشکل پیشنهاد شده است که با توجه به قسمت‌های مختلف سیستم در این فصل به بررسی انواع روش‌های انجام شده خواهیم پرداخت.

۲-۲ مفاهیم اساسی

در ابتدا مروی کلی بر مفاهیم استفاده شده در مقالات خواهیم داشت و در ادامه به توضیح انواع روش‌ها و بررسی مقالات خواهیم پرداخت.

۱-۲-۲ تصاویر دو بعدی و سه بعدی

همانطور که از تصویر ۲-۲ بر می‌آید یک تصویر را می‌توان به عنوان یک تابع $I(i, j)$ در فضای دو بعدی و یا تابع $I(i, j, k)$ در فضای سه بعدی تعریف کرد که در آن $i = 0, \dots, M - 1$, $j = 0, \dots, N - 1$, $k = 0, \dots, D - 1$ مختصات مکانی را مشخص می‌کنند. مقادیر (یا دامنه) تابع $I(i, j)$ و $I(i, j, k)$ مقدار شدت^۱ هستند و به طور معمول با مقدار خاکستری

در MRI مغز نشان داده می‌شود.^[۷]

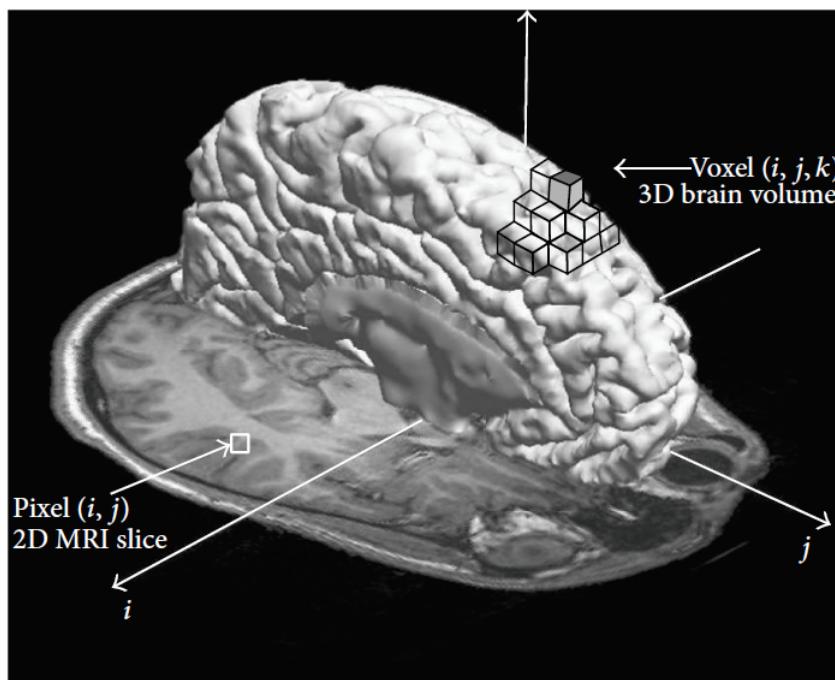
همانطور که در تصویر ۱-۲ قابل مشاهده می‌باشد هر تصویر شامل یک مجموعه محدود از عناصر تصویری به نام پیکسل^۲ در فضای دو بعدی و یا واکسل^۳ در فضای سه بعدی است. هر عنصر تصویر به وضوح توسط مقدار شدت آن و مختصات آن مشخص می‌شود

.^[۷]

^۱Intensity

^۲Pixel

^۳Voxel



شکل ۲-۱: تصویری از عناصر تصویر در MRI مغز [۷].

۲-۲-۲ مفهوم قطعه بندی تصویر

هدف تقسیم بندی^۱ تصویر این است که یک تصویر را به مجموعه‌ای از مناطق معنی دار، همگن و غیر یکپارچه از ویژگی‌های مشابه مانند شدت، عمق، رنگ، یا بافت مانند تصویر ۲-۳ تقسیم شود. نتیجه تقسیم بندی، یا یک تصویر از برچسب‌ها تمیز داده شده هر منطقه همگن است و یا مجموعه‌ای از خطوط که مرزهای منطقه را توصیف می‌کند [۷].

مؤلفه‌های اصلی تجزیه و تحلیل تصاویر MRI مغزی شامل طبقه بندی داده‌ها به انواع بافت خاص و شناسایی و توصیف ساختارهای آن‌ها می‌باشد. طبقه بندی به این معنی است که به هر عنصر در تصویر یک کلاس بافت، که از پیش تعریف شده‌اند اختصاص داده شود. مشکلات تقسیم بندی و طبقه‌بندی به یکدیگر مرتبط می‌باشند چون عملیات تقسیم بندی، طبقه بندی را نیز شامل می‌شود. در تصاویر MRI مغزی، عموماً عناصر تصویر به یکی از بافت‌های اصلی WM^۲, GM^۳, CSF^۴ تقسیم می‌شوند [۷].

تقسیم بندی تصویر را هم می‌توان بر روی تصاویر دو بعدی و هم تصاویر سه بعدی انجام داد. تمرکز بیشتر تحقیقاتی تقسیم بندی تصاویر بر روی تصاویر دو بعدی بوده است. اگر داده‌های موجود در فضای سه بعدی باشند عموماً تصاویر را "برش به برش"^۵ تقسیم بندی می‌کنند. این نوع از تقسیم بندی تصاویر سه بعدی نیازمند یک مرحله پس‌پردازش می‌باشد تا بخش بندی برش‌های دو بعدی

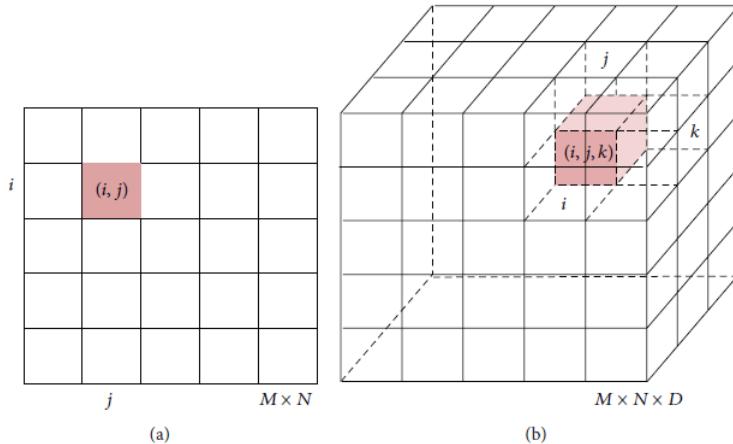
^۱Image Segmentation

^۲White matter

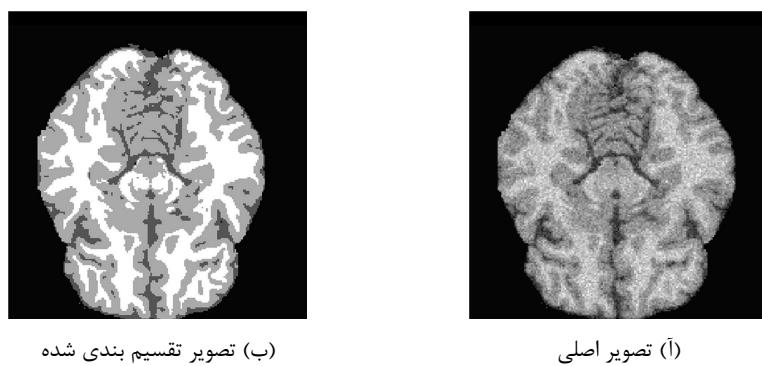
^۳Gray matter

^۴Cerebrospinal fluid

^۵slice-by-slice



شکل ۲-۲: نمایش عناصر تصاویر در فضای دو بعدی و سه بعدی [۷].



شکل ۲-۳: نمونه‌ای از یک تصویر MRI [۷]

را به یکدیگر متصل کرده و یک تصویر سه بعدی را ایجاد کند. تفاوت عمده بین تقسیم بندی تصاویر سه بعدی و دو بعدی در نحوه پردازش اجزای تصاویر می‌باشد. در عمل روش‌های تقسیم بندی دو بعدی قابل تعمیم به تصاویر سه بعدی می‌باشند اما در موقعی با افزایش پیچیدگی همراه می‌باشد [۷].

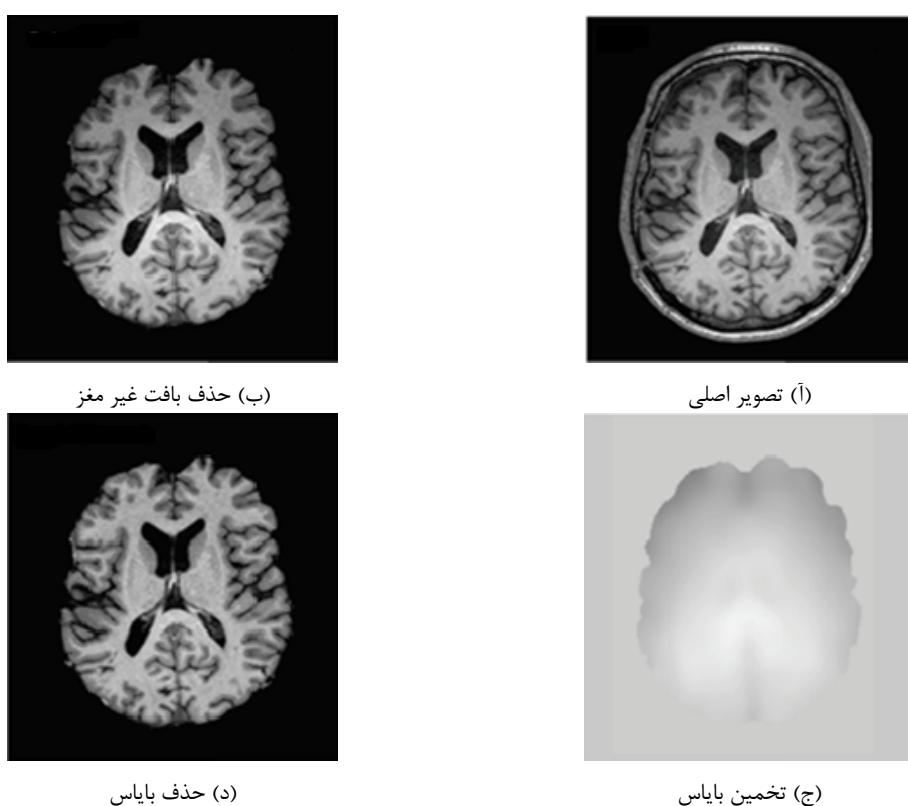
۳-۲-۲ ویژگی تصاویر

ویژگی‌های تصویر بیان کننده مشخصات خاص از یک شی یا ساختار یک تصویر برای الگوریتم‌های تقسیم بندی می‌باشند. ویژگی‌ها بر اندازه گیری‌های عددی از جمله بصری کمی و توصیف‌گرهای شکل که می‌توانند به تفاوت میان ساختارهای مورد علاقه و پس زمینه آن‌ها کمک کنند مตکی هستند. نتیجه گیری تقسیم بندی تصویر تا حد زیادی به انتخاب ویژگی مناسب و استخراج دقیق ویژگی بستگی دارد [۷]. معمولاً، روش‌های آماری برای استخراج ویژگی و طبقه بندی در تصاویر MRI مورد استفاده قرار می‌گیرد، که در آن الگو یا بافت با مجموعه‌ای از ویژگی‌های استخراج شده از نظر آماری به عنوان یک بردار در فضای ویژگی چند بعدی معروفی

می‌شود. ویژگی‌های آماری مبتنی بر داده‌های مرتبه اول و دوم از شدت سطح خاکستری در یک تصویر می‌باشد. ویژگی‌های مرتبه اول از هیستوگرام سطوح خاکستری تصویر بدست آمده و شامل شدت^۱، میانگین^۲، میانه^۳، انحراف معیار^۴ از سطوح خاکستری پیکسل‌ها می‌باشد. از آنجایی که این ویژگی‌ها اطلاعاتی در مورد توزیع مکانی پیکسل‌ها در اختیار ما قرار نمی‌دهد، معمولاً از ترکیب آن‌ها با ویژگی‌های مرتبه دوم استفاده می‌شود. ویژگی‌های مرتبه دوم برای توصیف بافت تصویر استفاده می‌شوند و معمولاً با استفاده از ماتریس هم‌رخدادی^۵ خاکستری محاسبه می‌شوند [۷].

۳-۲ پیش‌پردازش تصاویر MRI

پس از تصویر برداری چندین مرحله پیش‌پردازش برای اعمال رویکردهای قطعه‌بندی بر تصویر نیاز می‌باشد. مهمترین مراحل پیش‌پردازش، مراحل حذف میدان بایاس^۶، تطبیق تصاویر، حذف بافت غیر مغز می‌باشد [۷].



شکل ۳-۲: مراحل پیش‌پردازش [۷].

^۱Intensity

^۲Mean

^۳Median

^۴Standard Deviation

^۵Co-occurrence

^۶Bias field

۱-۳-۲ حذف میدان بایاس

بیشتر الگوریتم‌های بخش‌بندی که به طور وسیعی از آن‌ها استفاده می‌گردد بر مبنای ناحیه‌بندی بوده و معمولاً بر روی یکنواختی شدت‌های تصاویر MRI در ناحیه مورد نظر تکیه دارند. در بیشتر موارد به دلیل وجود یک عامل ذاتی که از آن تحت عنوان ناهمگنی شدت یاد می‌شود، بخش‌بندی دچار خطا می‌گردد.

در تصاویر MRI مغزی به دلیل وجود همپوشانی بین محدوده‌های شدت نواحی مختلف مغزی شامل GM، WM و CSF همواره با ناهمگنی شدت مواجه هستیم که به صورت تجمع انژی در نواحی نامبرده شده دیده می‌شوند و تحت نام میدان بایاس شناخته می‌شوند. لذا جهت بخش‌بندی دقیق تصاویر فوق نیاز به یک روش تخمین و اصلاح میدان بایاس داریم.

میدان بایاس همچنین ناهمگونی شدت نیز نامیده می‌شود یک اثر مصنوعی MRI با فرکانس پایین می‌باشد که موجب هموار شدن شدت سیگنال در بافت با خواص فیزیکی مشابه می‌شود. میدان بایاس وابسته به قدرت میدان مغناطیسی است [۸، ۲۰]. نمونه‌ای از حذف میدان بایاس از تصاویر MRI در تصویر ۵-۵ قابل مشاهده می‌باشد.



(ب) تصویر اصلاح شده



(آ) تصویر با میدان بایاس

شکل ۲-۵: نمونه‌ای از حذف میدان بایاس از تصویر [۸].

۱-۱-۳-۲ مدل‌های ناهمگنی شدت

مدل‌های مختلف تصویر سازی MRI در قبیل به طور مختصر ارائه شد با توجه به نوع تصویر سازی می‌تواند مدل مختلفی از ناهمگنی اتفاق می‌افتد، در ساده‌ترین مدل، فرض می‌شود که عامل خرابی به صورت ضرب‌شونده یا جمع شونده باشد به عنوان مثال، میدان ناهمگنی شدت، در شدت روش‌نایی تصویر ضرب می‌شود یا به شدت تصویر می‌افزاید [۲۰]. برای مدل سازی ناهمگنی‌هایی که به علت جریان‌های القایی و تحریک غیر یکنواخت هستند، مدل ضرب شونده کمتر مناسب می‌باشد. همچنین علاوه بر ناهمگنی شدت،

مدل تشکیل تصاویر MRI باید نویز با فرکانس بالا را نیز شامل شود. که این نویز شناخته شده و دارای توزیع Rician می‌باشد. با این حال، تا زمانی که نسبت سیگنال به نویز (SNR) خیلی کم نیست، نویز را می‌توان با توزیع شبه گاوس تقریبی زد. این تقریب زدن فقط برای تصاویر بافتی مناسب می‌باشد و برای تصاویری که از نوع بافت نباشند چندان کارآمد نمی‌باشد.

وابسته به این که تصویر عاری از ناهمگنی ($u(x)$), میدان بایاس ($b(x)$) و نویز ($n(x)$) بایکدیگر چه تعاملی داشته باشند، مدل‌های مختلفی از شکل گیری تصویر MRI ارائه شده است [۲۰]. پر کاربردترین مدل شکل گیری تصویر MRI فرض می‌کند که نویز که با توزیع احتمالی گاوسی تقریب زده می‌شود، از اسکنر بوجود می‌آید و بنابراین مستقل از میدان بایاس است. با توجه به این مدل، می‌توان رابطه شکل گیری تصویر ($v(x)$) را به صورت زیر نوشت [۲۰]

$$v(x) = u(x)b(x) + n(x) \quad (1-2)$$

در مدل دیگری از شکل گیری تصویر MRI، تنها نویز بیولوژیکی^۱ در نظر گرفته می‌شود که توسط میدان بایاس تحت تاثیر قرار می‌گیرد [۲۰]

$$v(x) = (u(x) + n(x))b(x) \quad (2-2)$$

سومین مدل شکل گیری MRI مبتنی بر لگاریتم است که توسط آن میدان بایاس ضرب شونده در مدل اول به میدان بایاس جمع شونده تبدیل می‌شود [۲۰]

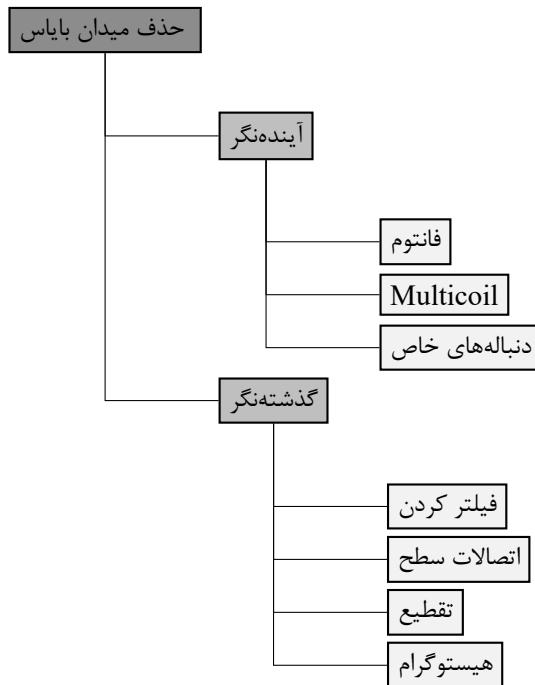
$$v(x) = \log u(x) + \log b(x) + n(x) \quad (3-2)$$

۲-۱-۳-۲ انواع روش‌های حذف میدان بایاس

در دو دهه گذشته روش‌های حذف میدان بایاس فراوانی پیشنهاد شده است. در ادامه یک دسته‌بندی از انواع روش‌های موجود و مزایا و معایب هر یک از روش‌ها ارائه شده است. معمولاً روش‌های حذف میدان بایاس به دو کلاس کلی با نام‌های آینده‌نگر و گذشته‌نگر یا بازبینی شده تقسیم می‌شوند. رویکرد اول با هدف کالیبره کردن و بهبود فرایند اکتساب تصویر است در حالی که رویکرد دوم به شدت وابسته به اطلاعات تصویر گرفته شده و گاهی دانش قبلی می‌باشد [۹، ۲۱، ۲۰]. روش‌های حذف میدان بایاس به صورت زیر

دسته‌بندی می‌شوند:

^۱Biological noise



شکل ۲-۶: روش‌های حذف میدان بایاس [۹]

- روش‌های آیندهنگر: این دسته از روش‌ها به اصلاح انحراف شدت ناشی از میدان بایاس که به عنوان یک خطای سیستماتیک

در فرایند تصویر برداری MRI به وجود می‌آید می‌پردازد. این دسته از روش‌ها، خود به سه زیردسته، روش‌های مبتنی بر

فانتوم، روش‌های مبتنی بر Multicoil و روش‌های مبتنی بر دباله‌های خاص تقسیم می‌شود [۹].

- روش‌های گذشتهنگر: این دسته از روش‌ها نسبتاً عمومی هستند، زیرا تنها چند فرضیه در مورد فرآیند حذف میدان بایاس

معمولًا مورد استفاده قرار می‌گیرد. این روش‌ها عمدتاً بر اطلاعات تصاویر به دست آمده که در آن اطلاعات مفیدی نظری

اطلاعات آناتومیکی و اطلاعات در مورد عدم همبستگی شدید تکیه می‌کنند. در مقایسه با روش‌های آیندهنگر، که تنها

می‌تواند ناهمگونی شدت ناشی از یک اسکنر MRI را اصلاح کند، روش‌های گذشتهنگر می‌تواند عدم انحراف بودن وابسته

به بیمار را نیز حذف کند. در ادامه به توضیح بیشتر هر یک از روش‌های مربوط به این دسته پرداخته خواهد شد.

- روش‌های مبتنی بر فیلتر کردن: این روش‌ها فرض می‌کنند که ناهمگنی شدت، یک خرابی مصنوعی با فرکانس پایین

است که می‌توان این خرابی را از سیگنال با فرکانس بالای ساختارهای آناتومیکی با یک فیلتر پایین گذر جدا کرد.

یکی از مشکلات این روش آن است که از آنجایی که کنتراست تصویر بالا می‌باشد عمل فیلترینگ، مصنوعات را به

عنوان لبه می‌شناسد بنابراین این عمل فیلتراسیون باعث خرابی در لبه‌ها می‌شود که خود را به عنوان تحریف یک

بافت همگن در نزدیکی لبه‌ها نشان می‌دهد.

دو روش اصلی فیلتر کردن، فیلتر کردن Homomorphic و Homomorphic unsharp masking(HUM) هستند.

پیشنهاد شده است.

فیلترینگ همومورفیک: این نوع فیلترینگ به صورت زیر اعمال می‌شود:

$$\log u(x) = \log v(x) - LPF(\log v(x)) + C_N \quad (4-2)$$

که در آن تصویر ورودی تبدیل یافته (با استفاده از تابع لگاریتم) از تصویر فیلتر شده به وسیله فیلتر پایین گذر تفرقی می‌شود و این به عنوان یک تخمین از میدان بایاس در نظر گرفته می‌شود و در نهایت یک ثابت عددی C_N به عنوان نرمال کننده به تصویر اضافه می‌شود.

فیلترینگ HUM: این روش برای اولین بار توسط آقای Axel Axelson پیشنهاد شد و یکی از ساده‌ترین و رایج‌ترین روش‌ها برای اصلاح میدان بایاس می‌باشد. در این روش تصحیح میدان بایاس به روش زیر صورت می‌گیرد:

$$u(x) = \frac{v(x)}{b(x)} = \frac{v(x)C_N}{LPF(v(x))} \quad (5-2)$$

که در این روش تصویر اصلاح شده از تقسیم تصویر ورودی بر اعمال یک فیلتر پایین گذر بر تصویر ورودی بدست می‌آید. که این فیلتر پایین گذر می‌تواند یک فیلتر میانگین یا میانه باشد. اثبات شده است که فیلتر میانگین برای تصاویر مغزی نتایج بهتری را دارد.

◦ روش‌های مبتنی بر برآذش سطح

این روش‌ها، یک سطح پارامتری را بر روی ویژگی‌هایی از تصویر که شامل اطلاعات ناهمگنی شدت هستند، برآذش می‌کنند. با توجه به ویژگی‌های تصویری که برای برآذش سطح استفاده می‌شود، روش‌های برآذش سطح بیشتر به روش‌های مبتنی شدت روشنایی و مبتنی بر گرادیانی دسته بندی می‌شوند.

◦ روش‌های مبتنی بر تقسیم‌بندی تصحیح میدان بایاس اغلب یک مرحله پیش پردازش برای الگوریتم‌های تقسیم‌بندی می‌باشد که امکان تقسیم تصویر بهتر را فراهم می‌آورد. بنابراین اصلاح و تقسیم ناهمگنی شدت می‌تواند به عنوان دو رویه در هم آمیخته شود. این دسته از روش‌ها خود به زیردسته‌هایی نظیر Fuzzy c-means و MAP، ML و

روش‌های غیرپارامتری تقسیم می‌شوند.

روش‌های حداکثر احتمال (ML) یا معیار حداکثر احتمال پیشین (MAP) ممکن است برای تخمین توزیع احتمال شدت روشنایی تصویر با استفاده از مدل‌های پارامتری استفاده شود. روش‌های Fuzzy c-means این روش‌ها

از تقسیم بندی استاندارد فازی استفاده می‌کنند و تابع هدف را برای تطبیق با عدم هماهنگی شدت تغییر می‌دهد.

ویژگی اصلی روش FCM، مدل طبقه بندی نرم است که فرض می‌کند که واکسل‌های تصویر متعلق به بیش از یک کلاس هستند. و این نوع مدل سازی باعث می‌شود تا کلاس‌هایی که در یکدیگر ادغام شده‌اند از یکدیگر جدا شوند. در روش‌های غیرپارامتری از طبقه‌بندهای غیرپارامتری استفاده می‌کنند. این‌گونه از روش‌ها نیازمند هیچ دانش پیشین در مورد توزیع احتمال شدت روشنایی مانند میانگین و واریانس بافت کلاس نمی‌باشند و واکسل‌ها را با توجه به حالت‌های اصلی فضای مورد نظر دسته بندی می‌کنند.

◦ روش‌های مبتنی بر هیستوگرام

روش‌های مبتنی بر هیستوگرام به طور مستقیم بر روی هیستوگرام‌های شدت تصویر عمل می‌کنند و نیازی به مقدار اولیه و یا دانش پیشینی در توزیع احتمالی شدت ساختارهای تصویری ندارند. این باعث می‌شود این روش‌ها به طور کامل اتوماتیک و به طور عمومی بر روی هر نوع تصاویری (با آسیب یا بدون آسیب) اعمال شوند. اگر چه تعدادی از روش‌های مبتنی بر تقسیم بندی نیز بر روی هیستوگرام‌های شدت تصویر کار می‌کنند، تفاوت روش‌های مبتنی بر تقسیم بندی و هیستوگرام این است که روش‌های مبتنی بر هیستوگرام هیچ نتیجه تقسیم بندی اولیه‌ای را ارائه نمی‌دهد.

ماکریم کردن فرکانس بالا: یک روش اصلاح میدان بایاس شناخته شده، به نام N3 می‌باشد، که در [۸] پیشنهاد شده است. این روش تکراری است و به دنبال یافتن فیلد هموار کننده ضرب شونده می‌باشد که سعی در به حداقل رساندن جز فرکانس بالای توزیع شدت بافت دارد. این روش کاملاً اتوماتیک است، و نیاز به دانش پیشین ندارد و همچنین می‌تواند تقریباً برای هر تصویر MRI استفاده شود.

کمینه سازی اطلاعات: این روش‌ها بر این فرض استوار است که ناهمگنی شدت به عنوان اطلاعات اضافی در تصویر عاری از میدان بایاس (تصویر صحیح) می‌باشد. بنابراین حذف ناهمگنی شدت در این روش‌ها براساس محدود کردن حداقل اطلاعات تصویر می‌باشد که توسط آنتروپی تصویر برآورده می‌شود. روش‌های به حداقل رساندن اطلاعات می‌توانند به طور گستره‌های برای انواع مختلف تصاویر MRI مورد استفاده قرار گیرد زیرا تنها از اطلاعات موجود در یک تصویر استفاده می‌کنند بدون این که فرض بر روی توزیع‌های مکانی و شدت وجود داشته باشد.

تطبیق هیستوگرام: در این دسته از روش‌ها سعی دارند با توجه به یک تصویر سالم و بدون ناهمگنی شدت، تصاویری که دارای میدان بایاس می‌باشند را تصحیح کنند که این عمل با استفاده از تکنیک‌های پردازش تصویر و توسط

الگوریتم تطبیق هیستوگرام سعی دارد هیستوگرام دو تصویر را بریکدیگر تطبیق دهد تا میدان بایاس ایجاد شده در

تصویر از بین برود.

داوانت و همکاران [۲۲] روشی را مطرح کردند که ناهمگنی شدت را از طریق متناسب سازی با یک سری نوارهای باریک نسبت به

نقاط انتخاب شده در درون هر ناحیه بافت مغزی، تخمین می‌زنند. بدین صورت که در ابتدا یک نوار نازک از یک بافت خاص را انتخاب

کرده و با توجه به سطح روشنایی اصلی سعی در تخمین ناهمگنی شدت دارد. روش دیگری بر مبنای هیستوگرام شدت برای اصلاح

میدان بایاس بهنام N3 توسط تاستیسور و همکاران [۲۲] مطرح گردید.

در سال ۲۰۱۴^۱ لی^۱ و همکاران [۱۰] یک روشی برای تخمین میدان بایاس مبتنی بر تقسیم بندی و همچنین یک قطعه بندی اولیه

تصاویر MRI ارایه دادند که در ابتدا یک تابع هزینه جدیدی را معرفی کرده و سپس سعی در به حداقل رساندن آن را دارند. فرمول

بندی این مقاله برای تخمین بایاس و همچنین قطعه بندی بافت مبتنی بر تجزیه تصویر MRI به دو جز ضرب شونده می‌باشد که

در رابطه زیر نمایش داده شده است:

$$I(x) = b(x)J(x) + n(x) \quad (6-2)$$

که در آن $I(x)$ مقدار سطح روشنایی شده در واکسل (x) ، $J(x)$ مقدار سطح روشنایی تصویر عاری از میدان بایاس (تصویر

درست)، $b(x)$ میدان بایاس موجود در تصویر مشاهده شده و همچنین $n(x)$ یک نویز جمع شونده با میانگین صفر می‌باشد.

تصویر واقعی $J(x)$ خصوصیات فیزیکی بافت‌هایی که در حال تصویر برداری هستند را مشخص می‌کند، که به طور ایده آل برای

واکسل‌هایی که درون یک نوع نوع بافت قرار می‌گیرند، ارزش خاصی دارند. بنابراین، فرض شده است که $J(x)$ تقریباً یک ثابت c_i

برای تمام نقاط x در بافت Ω است. برآورد مولفه‌های $b(x)$ و $J(x)$ هیچ دانش در مورد آن‌ها مورد استفاده قرار نگیرد، یک

مسئله نامطلوب یا بدینانه می‌باشد.

برای حل این مسئله در این مقاله بعضی از دانش‌های اولیه در مورد میدان بایاس و تصویر صحیح استفاده شده است. در این مقاله

متندی که پیشنهاد شده است از ویژگی‌های پایه‌ای در تصویر صحیح به نام ویژگی قطعه قطعه ثابت^۲ و همچنین هموار بودن تصویر

میدان بایاس استفاده شده است.

برای استفاده موثر از این ویژگی‌های معروفی شده یک نمایش ریاضی مناسب برای توصیف میدان بایاس استفاده شده است. در این

متند میدان بایاس با استفاده از ترکیب خطی تعدادی توابع پایه هموار g_M, g_1, \dots, g_n نمایش داده شده است. به لحاظ نظری، یک

¹Li

²piecewise constant

تابع را می‌توان با ترکیب خطی تعدادی از توابع پایه تا دقت دلخواه تقریب کرد [۲۴] که هر چه تعداد توابع پایه (M) بیشتر باشد

دقت تخمین بیشتر خواهد شد. در این مقاله از ۲۰ تابع چند جمله‌ای تا حداقل درجه سه استفاده شده است.

تخمین میدان بایاس با یافتن ضرایب بهینه w_1, \dots, w_M در ترکیب خطی $b(x) = \sum_{k=1}^M w_k g_k$ بدست می‌آید. برای

نمایش بهتر از نمایش برداری وزن‌ها استفاده شده است بدین صورت که ضرایب را به صورت یک بردار ستونی به صورت W =

$G(x) = (g_1(x), \dots, g_M(x))^T$ (w_1, \dots, w_M)^T که بیانگر ترانهاده می‌باشد. همچنین تابع پایه به صورت

نمایش داده شده است. بنابراین میدان بایاس را می‌توان به صورت زیر تخمین زد:

$$b(x) = W^T G(x) \quad (7-2)$$

همچنین خصوصیت قطعه‌ای ثابت از تصویر واقعی J می‌تواند به طور خاص به شرح زیر بیان شود. اگر فرض شود که N نوع بافت در

کل دامنه تصویر (Ω) وجود داشته باشد بنابراین در تصویر صحیح $J(x)$ مقدار سطح روشنایی یک مقدار ثابت c_i برای هر پیکسل

x که متعلق به بافت i می‌باشد. هر ناحیه بافت (Ω_i) با یک تابع عضویت (u_i) نمایش داده می‌شود. در حالت ایده‌آل هر واکسل

دقیقاً متعلق به یک بافت می‌باشد که به این تابع عضویت، تابع عضویت باینری گفته می‌شود و به صورت زیر تعریف می‌شود.

$$u_i(x) = \begin{cases} 1 & x \in \Omega_i \\ 0 & x \notin \Omega_i \end{cases} \quad (8-2)$$

بنابراین با توجه به تابع عضویت و مقدار ثابت تعریف شده برای هر بافت می‌توان نوشت:

$$J(x) = \sum_{i=1}^N c_i u_i(x) \quad (9-2)$$

بر اساس مدل تصویر (۱)، یک روش بهینه سازی انرژی برای تخمین میدان بایاس و تقسیم بندی بافت پیشنهاد داده شده است.

نتیجه تقسیم بندی بافت توسط تابع عضویت مشخص می‌شود و در نهایت پس از تخمین میدان بایاس، تصویر صحیح را می‌توان از

رابطه I/b بدست آورد. تابع هزینه پیشنهادی برای تخمین میدان بایاس و همچنین تقسیم بندی اولیه بافت مبتنی بر مدل شکل

گیری ۱-۲ بدین صورت می‌باشد:

$$F(b, J) = \int_{\Omega} |I(x) - b(x)J(x)|^r dx \quad (10-2)$$

با توجه به ویژگی‌های معروفی شده در مورد تصویر صحیح و تصویر میدان بایاس بنابراین می‌توان تابع هزینه را به صورت زیر تغییر

داد:

$$F(b, J) = F(u, c, w) = \int_{\Omega} |I(x) - W^T G(x) \sum_{i=1}^N c_i u_i(x)|^r dx \quad (11-2)$$

در ادامه می‌توان به صورت زیر ساده سازی را انجام داد:

$$\begin{aligned} F(u, c, w) &= \int_{\Omega} |I(x) - W^T G(x) \sum_{i=1}^N c_i u_i(x)|^r dx \\ &= \sum_{i=1}^N \int_{\Omega_i} |I(x) - W^T G(x) c_i|^r dx \quad (12-2) \\ &= \sum_{i=1}^N \int_{\Omega} |I(x) - W^T G(x) c_i|^r u_i(x) dx \end{aligned}$$

در ادامه با توجه به مشخص شدنتابع هزینه حال باید هریک از پارامترها را بهینه کرد که در ادامه توضیح داده خواهد شد. با ثابت

در نظر گرفتن w و u برای مینمم کردن تابع هزینه با توجه به متغیر c می‌بایست از تابع هزینه نسبت به c مشتق گرفت و برابر

صفر قرار داد بنابراین قانون آپدیت متغیر c به صورت زیر می‌باشد:

$$c_i = \frac{\int_{\Omega} I(x) b(x) u_i(x) dx}{(\int_{\Omega} b^r(x) u_i(x) dx)} \quad i = 1, \dots, N \quad (13-2)$$

با ثابت در نظر گرفتن c و u برای کمینه کردن تابع هزینه از تابع هزینه نسبت به w مشتق گرفته و برابر صفر قرار می‌دهیم:

$$\frac{\partial F}{\partial W} = -v + AW \quad (14-2)$$

که داریم:

$$v = \int_{\Omega} G(x) I(x) \left(\sum_{i=1}^N c_i u_i(x) \right) dx \quad (15-2)$$

$$A = \int_{\Omega} G(x) G^T(x) \left(\sum_{i=1}^N c_i u_i(x) \right) dx \quad (16-2)$$

سپس مقدار مشتق را برابر صفر قرار می‌دهیم و داریم

$$v = AW \Rightarrow W = A^{-1}v \quad (17-2)$$

بنابراین قانون آپدیت w را می‌توان به صورت زیر نوشت

$$W = \left(\int_{\Omega} G(x) G^T(x) \left(\sum_{i=1}^N c_i u_i(x) \right) dx \right)^{-1} G(x) I(x) \left(\sum_{i=1}^N c_i u_i(x) \right) dx \quad (18-2)$$

و در نهایت با ثابت فرض کردن c و w قانون آپدیت u به صورت زیر خواهد بود:

$$u_i(x) = \begin{cases} 1 & i = i_{min} \\ 0 & i \neq i_{min} \end{cases} \quad (19-2)$$

که در آن داریم:

$$i_{min}(x) = \arg \min \{\delta_i(I(X))\} \quad (20-2)$$

$$\delta_i(x) = |I(X) - W^T G(x)c_i|^r \quad (21-2)$$

به طور خلاصه می‌توان الگوریتم پیشنهادی به صورت زیر نوشت:

- مرحله اول: مقدار دهی اولیه C و u
- مرحله دوم: محاسبه b طبق رابطه ۷-۲
- مرحله سوم: به روزرسانی C طبق رابطه ۱۳-۲
- مرحله چهارم: به روزرسانی u طبق رابطه ۱۹-۲
- مرحله پنجم: چک کردن شرط همگرایی اگر شرط همگرایی برآورده نشده بود به مرحله ۲ برو.

شرط همگرایی استفاده شده در مرحله پنجم در این الگوریتم پیشنهادی به صورت زیر می‌باشد:

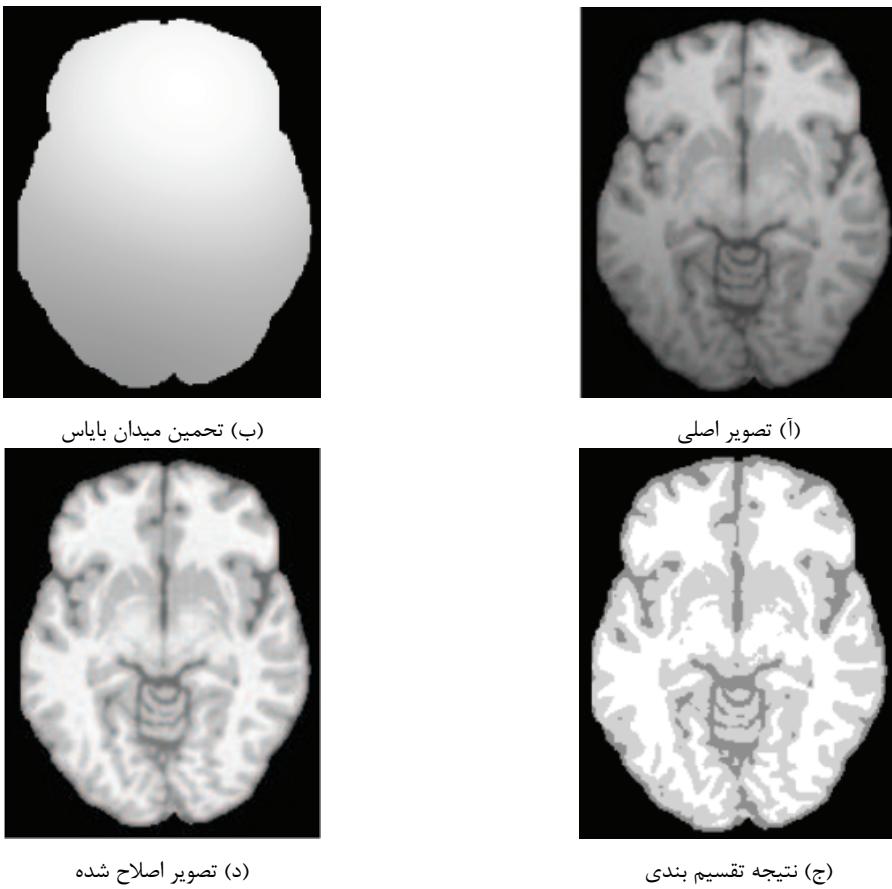
$$|c^{(n)} - c^{(n-1)}| < \epsilon \quad (22-2)$$

که در آن ϵ برابر با $1 \cdot 10^{-6}$ در نظر گرفته شده است. نتایج حاصل از پیاده سازی این روش در شکل ۷-۲ نمایش داده شده است.

۲-۳-۲ تطبیق تصاویر

تطبیق تصویر یک گام لازم برای گنجاندن اطلاعات احتمالی به عنوان دانش پیشین از آناتومی مغز به روش تقسیم بندی است.

تطبیق تصویر فرآیند روی یکدیگر قرار دادن (هماهنگی مکانی) دو یا چند تصویر از محتوا گرفته شده یکسان در زمان‌های مختلف، از دیدگاه‌های مختلف و/یا توسط سنسورهای مختلف است. در تجزیه و تحلیل تصویر پزشکی برای کسب اطلاعات کامل در مورد سلامت بیمار، با استفاده از تصاویر چندتایی (مانند MRI، CT، SPECT و PET)، و برای تایید درمان با مقایسه تصاویر قبل و بعد از مداخله، تطبیق مورد نیاز می‌باشد [۲۵]. تطبیق تصویر شامل پیدا کردن پارامترهای تبدیل بین تصاویر است به طوری که ویژگی‌های تصاویر مربوطه به صورت مکانی بر روی یکدیگر قرار بگیرند [۷]



شکل ۷-۲: نتایج حاصل از پیاده سازی روش [۱۰]

هم ترازی مکانی به طور معمول با استفاده از تبدیل Rigid و یا Affine شروع می‌شود. تبدیل Rigid شش پارامتر تبدیل برای چرخش و انتقال نیاز دارد. در صورتی که مقیاس گذاری^۱ و skewing مورد نیاز است می‌بایست از ۱۲ پارامتر استفاده کرد [۷].

۳-۳-۲ حذف بافت غیر مغز

شدت روشنایی بافت‌های غیر مغز مانند چربی، جمجمه یا گردن با شدت بافت مغز همپوشانی دارند. بنابراین در تصاویر مغزی قبل از اعمال الگوریتم‌های قطعه‌بندی نیاز است تا بافت‌هایی غیر از مغز از تصویر MRI حذف شود تا در مرحله تقسیم بندی با مشکل مواجه نشویم. در واقع در این مرحله از پیش پردازش واکسل‌ها را به دو دسته مغز و یا غیر مغز طبقه بندی می‌کند. نتیجه این مرحله می‌تواند یک تصویر جدید با واکسل‌های مغز و یا یک ماسک باینری باشد که دارای مقدار یک برای واکسل‌های مغز و صفر برای سایر بافت‌ها است [۵] [۷]. روش معمول برای استخراج مغز، از اطلاعات قبلی آناتومی مغز استفاده می‌کنند. همانطور که در تصویر ۲-۸ یک الگو با قابلیت تغییر شکل را می‌توان با یک تصویر MRI بیمار تطبیق داد و سپس بافت مغزی و غیر مغزی از قالب

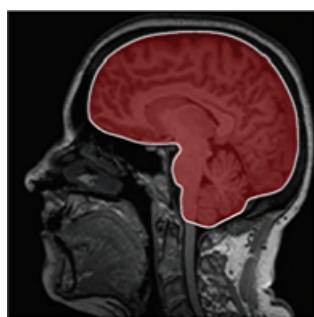
^۱scaling

حذف می‌شود. با این حال، استخراج مغز با استفاده از یک اطلس معمولاً خیلی دقیق نیست و می‌تواند کلاس غلط در اطراف مرز مغز

ایجاد کند. یک روش جایگزین برای استخراج مغز روش BET^۱ می‌باشد [۷].

روش BET یکی از بهترین روش‌های حذف جمجمه می‌باشد که در سال ۲۰۰۲ ارایه شد [۲۶]. در این روش از یک مرز فعال برای

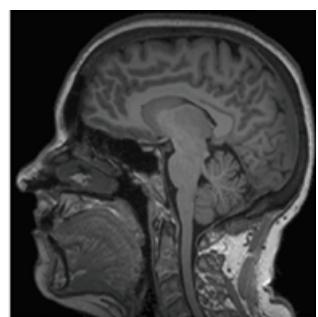
حذف جمجمه استفاده کرده است.



(ج) حذفت بافت غیر مغز



(ب) بافت مغز



(آ) تصویر اصلی

شکل ۸-۲: نمونه‌ای از حذف بافت غیر مغز [۷]

۴-۲ روش‌های قطعه‌بندی تصاویر MRI

به طور کلی، تقسیم بندی MRI یک کار بی اهمیت نیست، زیرا تصاویر MRI تصویربرداری شده ناقص هستند و اغلب توسط

نویز و سایر آثار مصنوعی تصویر خراب می‌شوند. تنوع برنامه‌های کاربردی پردازش تصویر منجر به توسعه تکنیک‌های مختلف برای

تقسیم‌بندی تصاویر شده است. این به این دلیل است که هیچ روش مناسب وجود ندارد که بتواند برای همه تصاویر مناسب باشد

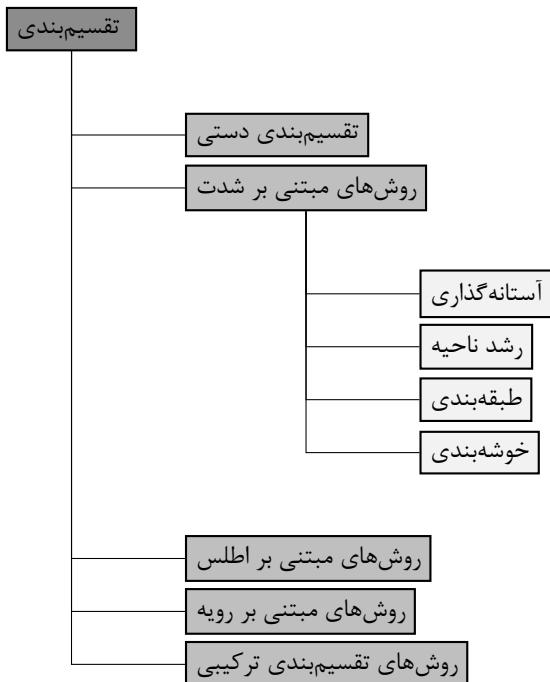
و همچنانی تمام روش‌ها برای یک نوع خاص از تصویر مناسب نیست. به عنوان مثال، برخی از روش‌ها فقط از هیستوگرام سطح

خاکستری استفاده می‌کنند، در حالی که بعضی از اطلاعات مکانی تصاویر را برای محیط‌های دارای نویز قوی استفاده می‌کنند [۷]

. [۲۵]

روش‌های تقسیم‌بندی با استفاده از MRI مغزی به صورت شکل ۹-۲ دسته‌بندی می‌شوند [۷]:

^۱brain extraction tool



[۷] دسته‌بندی روش‌های تقسیم‌بندی MRI

۱-۴-۲ تقسیم‌بندی دستی

تقسیم‌بندی دستی به فرآیندی اشاره دارد که در آن یک اپراتور انسان (به عنوان مثال، متخصص پزشکی) بخش‌ها و برچسب‌های یک تصویر را به صورت دستی مشخص می‌کند. در این روش تصاویر سه بعدی اصولاً به صورت "برش به برش"^۱ تقسیم‌بندی بر روی آن‌ها صورت می‌گیرد و هر صفحه به صورت مجزا تقسیم‌بندی می‌شود. اعتقاد بر این است که روش دستی بیشترین دقیقیت را در بین همه روش‌های موجود دارا می‌باشد و به دلیل دشوار بودن و دقیق بودن به یک ساختار قابل اعتماد در تصاویر پزشکی تبدیل شده است. مشکلات تقسیم‌بندی به کیفیت تصویر و اعوجاج‌های آن می‌باشد.

با توجه به پیشرفت‌هایی که طی سال‌های گذشته توسط ابزارهای تصویربرداری به دست آمده است، تقسیم‌بندی دستی به یک کار پر زحمت و وقت‌گیر تبدیل شده است. به عنوان مثال یک اپراتور آموزش دیده به طور معمول باید از طریق تقسیم‌بندی دستی ۵۱۲×۵۱۲ برش به برش ساختارهای آن‌ها را تقسیم‌بندی کند که این عمل بسیار وقت‌گیر می‌باشد. این روش تقسیم‌بندی تصویر ۵۱۲×۵۱۲ را تنها خسته کننده و وقت‌گیر می‌باشد بلکه بسیار مستعد اشتباه می‌باشد. همچنین نتایج تقسیم‌بندی دستی اغلب دشوار و حتی غیرممکن است که باز تولید شوند، زیرا حتی اپراتورهای مجرب تغییر قابل توجهی را نشان می‌دهند [۷].

با این حال، تقسیم‌بندی دستی هنوز هم به شدت مورد استفاده قرار می‌گیرد تا یک جایگزین برای تعریف و معیار درست تقسیم‌بندی

^۱slice-by-slice

برای انواع روش‌های تقسیم بندی تعریف شود. در واقع تقسیم بندی دستی یک معیار و ملاک برای ارزیابی کمی روش‌های خودکار می‌باشد.

۲-۴-۲ روش‌های مبتنی بر شدت

روش‌های تقسیم بندی مبتنی بر شدت پیکسل‌ها / واکسل‌های را فقط بر اساس مقدار شدت روشنایی آن‌ها طبقه بندی می‌کنند. همانطور که در فصل اول توضیح داده شد تصویر MRI مغز، سه بافت اصلی WM، GM، و CSF دارد که براساس شدت متفاوت می‌باشند. طبقه بندی دقیق‌تر ممکن نیست زیرا پروفایل‌های شدت ساختارهای دقیق‌تر مغز همپوشانی دارند. حتی جداسازی سه نوع بافت اصلی براساس شدت خود نیاز به ترکیب ابزارهایی برای برخورد با اعوجاج‌هایی مانند ناهمگنی شدید، نویز و همچنین همپوشانی شدت روشنایی بافت مغز و غیر مغز مانند پوست سر (پوست سر شدت روشنایی مشابهی با بافت مغز دارد)، چربی و ... در تصاویر MRI دارند. تکنیک‌های مبتنی بر شدت زیادی وجود دارد در ادامه چند زیردهسته از روش‌های مبتنی بر شدت را معرفی کرده و توضیحات مختصری در مورد آن‌ها داده خواهد شد.

- **آستانه‌گذاری:** آستانه‌گذاری ساده‌ترین روش تقسیم بندی تصویر است. یک روش آستانه‌ای استفاده از هیستوگرام شدت و تلاش برای تعیین مقادیر شدت آستانه τ ، که کلاس‌های مورد نظر را جدا می‌کند. روش‌های آستانه‌گذاری دارای نوع‌های زیادی می‌باشند: آستانه‌گذاری سراسری^۱ (یک آستانه)، آستانه‌گذاری محلی^۲ (وابسته به مکان در تصور می‌باشد)، چند آستانه‌ای^۳، آستانه‌گذاری وفقی^۴.

در آستانه‌گذاری سراسری، تقسیم بندی تصویر $(i.j)I$ به صورت زیر تعریف می‌شود:

$$u_i(x) = \begin{cases} 1 & \text{if } I(i,j) > \tau \\ 0 & \text{if } I(i,j) < \tau \end{cases} \quad (23-2)$$

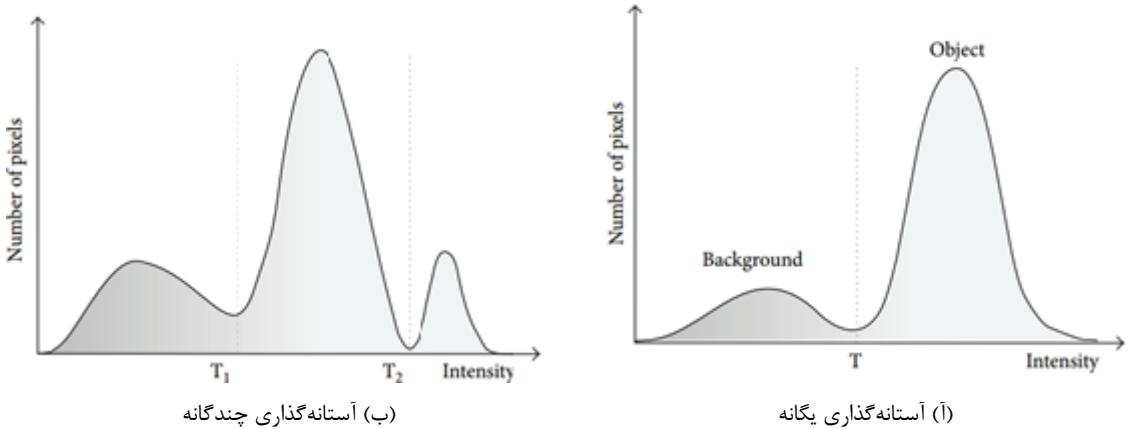
که در آن $(i.j)I'$ تصویر تقسیم شده می‌باشد و پیکسل‌های آن دارای مقادیر صفر و یک می‌باشند. شکل ۲-۱۰ آنمونه‌ای از یک آستانه‌گذاری سراسری می‌باشد. روش‌های آستانه‌گذاری بسیار سریع و از نظر محاسباتی کارآمد است، اما ویژگی‌های مکانی یک تصویر (اطلاعات محلی) را در نظر نمی‌گیرد. بنابراین این دسته از روش‌ها بسیار به نویز و ناهمگنی شدت حساس هستند. به طور کلی، روش‌های تقسیم‌بندی مبتنی بر آستانه‌گذاری برای تصاویر بافت مناسب نیستند. با این حال، در تقسیم

^۱Global thresholding

^۲Local thresholding

^۳Multi thresholding

^۴adaptive thresholding



شکل ۱۰-۲: تقسیم بندی مبتنی بر آستانه گذاری

بندی MRI مغزی، آستانه‌گذاری می‌تواند برای جدا کردن واکسل‌های پس زمینه از بافت مغزی یا برای مقداردهی اولیه برای کلاس‌های بافت در روش‌های تقسیم بندی تکراری مانند خوشه بندی به کار گرفته شود.

- **رشد ناحیه:** رشد ناحیه (همچنین به عنوان ناحیه ادغام نیز تعریف می‌شود) یک تکنیک برای استخراج یک منطقه متصل از تصویر است که شامل گروه‌های پیکسل / واکسل با شدت‌های مشابه می‌باشند. در ساده‌ترین شکل، ناحیه در حال رشد با یک نقطه (پیکسل / واکسل) که متعلق به جسم است، شروع می‌شود. نقطه شروع^۱ را می‌توان به صورت دستی توسط یک اپراتور انتخاب کرد یا به صورت خودکار با الگوریتم‌های جست و جو نقطه شروع^۲، آغاز شود. سپس، ناحیه در حال رشد تمام پیکسل‌ها / واکسل‌های همسایه را بررسی می‌کند و اگر شدت روشنایی آن‌ها به اندازه کافی مشابه باشد، آن پیکسل‌ها به ناحیه رو به رشد اضافه می‌شوند. این روند تکرار می‌شود تا هیچ پیکسل / واکسل دیگری به ناحیه اضافه نشود [۷]. ضعف اصلی روش‌های رشد ناحیه این است که به نقطه شروع بسیار حساس می‌باشند. با انتخاب یک نقطه شروع متفاوت، نتیجه تقسیم بندی می‌تواند کاملاً متفاوت باشد. اگر نقطه شروع و معیار شباهت به درستی تعریف نشده باشد، ناحیه رو به رشد می‌تواند با مناطقی که متعلق به جسم مورد نظر نیست ادغام شود و نتیجه تقسیم بندی درست نباشد. همچنین رشد ناحیه به نویز حساس می‌باشد و در صورت وجود نویز می‌تواند الگوریتم متوقف شود و یا در نتیجه نهایی حرفه ایجاد کند [۵].

- **طبقه بندی:** روش‌های طبقه بندی از داده‌هایی با برچسب‌های مشخص استفاده می‌کنند تا فضای تصویر را پارتیشن بندی کنند. ویژگی‌های تصویر معمولاً وابسته به مقدار شدت روشنایی هستند اما می‌توانند به بافت یا سایر خواص تصویر نیز مرتبط باشند. روش‌های طبقه بندی می‌توانند با ناظر و یا بدون ناظر باشند.

^۱seed point

^۲seed finding

رویکردهای با ناظر بر مبنای استفاده از نوع خاصی از اطلاعات پیشین یا دانش برای انجام تجزیه ضایعات MS می‌باشد [۵].

این دانش پیشین شامل تصاویر آموزش می‌باشد که به صورت دستی تقسیم بندی شده و سپس به عنوان مرجع برای تقسیم

خودکار تصاویر جدید استفاده می‌شود [۷]. در کنار اینکه تقسیم بندی دستی که سخت و وقت‌گیر است، یکی دیگر از

ضعف روش‌های طبقه بندی با ناظر این است که آن‌ها معمولاً اطلاعات محلی را در نظر نمی‌گیرند و بنابراین به نویز حساس

هستند [۵].

• خوش‌بندی: روش‌های خوش‌بندی روش‌های طبقه بندی بدون نظارت است که تصویر را بدون استفاده از داده آموزشی به

خوش‌های پیکسل‌ها / واکسل‌هایی با شدت روش‌نایی‌های مشابه تقسیم می‌کنند. در واقع، روش‌های خوش‌بندی از داده‌های

تصویر موجود برای آموزش خود استفاده می‌کنند. تقسیم بندی و آموزش به صورت موازی با تکرار بین دو مرحله انجام

می‌شود: خوش‌بندی داده‌ها و برآورد خواص هر کلاس از بافت [۷].

در مقاله‌ای در سال ۲۰۱۷ Birenbaum و همکاران [۱۱] یک روش مبتنی بر طبقه بندی ارایه دادند که رویکرد آن‌ها دارای سه

فاز اصلی پیش پردازش، استخراج نواحی کاندید، و در نهایت پیش بینی پلاک‌های بیماری با استفاده از CNN می‌باشد.

در این رویکرد فاز پیش پردازش شامل مجموعه پیش پردازش‌های متداول در اکثریت روش‌های تقسیم بندی تصاویر مغزی مانند

تطبیق، حذف بافت غیر مغز، حذف میدان بایاس و نرمال سازی شدت می‌باشد. در فاز استخراج نواحی کاندید، ماسک‌ها براساس

تصویر FLAIR و بافت WM، ساخته شده و به تصاویر MRI اعمال می‌شوند. در نهایت در فاز پیش بینی پلاک‌های بیماری از

یک شبکه کانولوشنی چند دید^۱ استفاده شده است. همچنین بسته به معیارهای ارزیابی تقسیم بندی، یک مرحله پس پردازش

اختیاری، که اجزای کوچک موجود در پیش بینی را رد می‌کند، می‌تواند اضافه شود.

• فاز پیش پردازش

در فاز پیش پردازش، ورودی سیستم یک مجموعه از تصاویر MRI شامل Proton ، T1-weighted ،T2- weighted

MRI می‌باشد. تصاویر مورد نیاز لزوماً مطابق یکدیگر نمی‌باشند و دارای اختلافاتی می‌باشند بنابراین ابتدا

باید تصاویر به یک فضای مشخصی تطبیق داده شوند که در این مرحله از یک تطبیق سخت استفاده شده است. در مرحله

دوم می‌باشد بافت‌های غیر مغز از تصاویر حذف شوند در این قسمت از روش BET و برای حذف بایاس بایاس فیلد از

روش N4ITK استفاده شده است.

¹multi-view CNN

نرمال‌سازی شدت پایان مرحله پیش پردازش می‌باشد؛ تصاویر با استفاده از روش تطبیق هیستوگرام به یک تصویر مرجع متناظر تطبیق داده می‌شود. این یک مرحله مهم قبل از پردازش اصلی است، از آنجایی که مقادیر تصویر FLAIR برای استخراج کاندید استفاده می‌شود و یک آستانه ثابت برای همه موارد FLAIR استفاده می‌شود. زمانی که تصاویر ورودی دارای دامنه‌های شدت متفاوت هستند نرمال بودن شدت برای مرحله پیش بینی نیاز است.

• فاز استخراج نواحی کاندید

این فاز از تعدادی ماسک اولیه برای تشخیص ضایعات استفاده می‌کند. در این مرحله یک زیر مجموعه کوچک از واکسل‌های تصویر به عنوان نامزدهای واکسل ضایعه انتخاب می‌شوند. و این زیر مجموعه کوچک از واکسل‌ها به عنوان ورودی به فاز پیش بینی با استفاده از شبکه کانولوشنی می‌باشد. در واقع این فاز حجم محاسبات را برای فاز بعدی کاهش می‌دهد. علاوه بر این، چون استخراج کاندید بر روی سطح واکسل عمل می‌کند، در حالی که فاز پیش بینی از اطلاعات محلی اطراف واکسل عمل می‌کند، این دو مرحله را می‌توان به عنوان یک خط لوله چند بعدی مورد بررسی قرار داد که هر دو مرحله محلی و نیمه محلی (همسایگی) برای به دست آوردن دقت تقسیم بندی بالا گنجانیده شده است.

در این مقاله دو مشاهدات بالینی اصلی برای روش استخراج کاندید استفاده می‌شود؛ اول، ضایعات به عنوان مناطقی با شدت روشنایی زیاد^۱ در تصاویر FLAIR به نظر می‌رسد؛ بنابراین می‌توان آن‌ها را به صورت آستانه‌گذاری ساده در تصویر FLAIR شناسایی کرد. دوم این‌که، ضایعات MS عمدها در WM یا در مرز بین WM و GM واقع شده است. برای ترکیب کردن این اطلاعات یک قالب WM احتمالاتی را با تصویر FLAIR تطبیق داده می‌شود. بنا به دلایلی ابتدا تصویر WM با یک شعاع مشخص R گسترش یافته می‌شود. ماسک کاندید مورد نظر به صورت زیر تعریف می‌شود:

$$M(x) = \begin{cases} 1, & I_{FLAIR}(x) > \theta_{FLAIR} \cap Dilate_R(WM(x)) > \theta_{WM} \\ 0, & otherwise \end{cases} \quad (24-2)$$

که در آن مقدار پارامترهای $(\theta_{FLAIR}, \theta_{WM}, R)$ با استفاده از اعتبار سنجی متقابل^۲ محاسبه می‌شود.

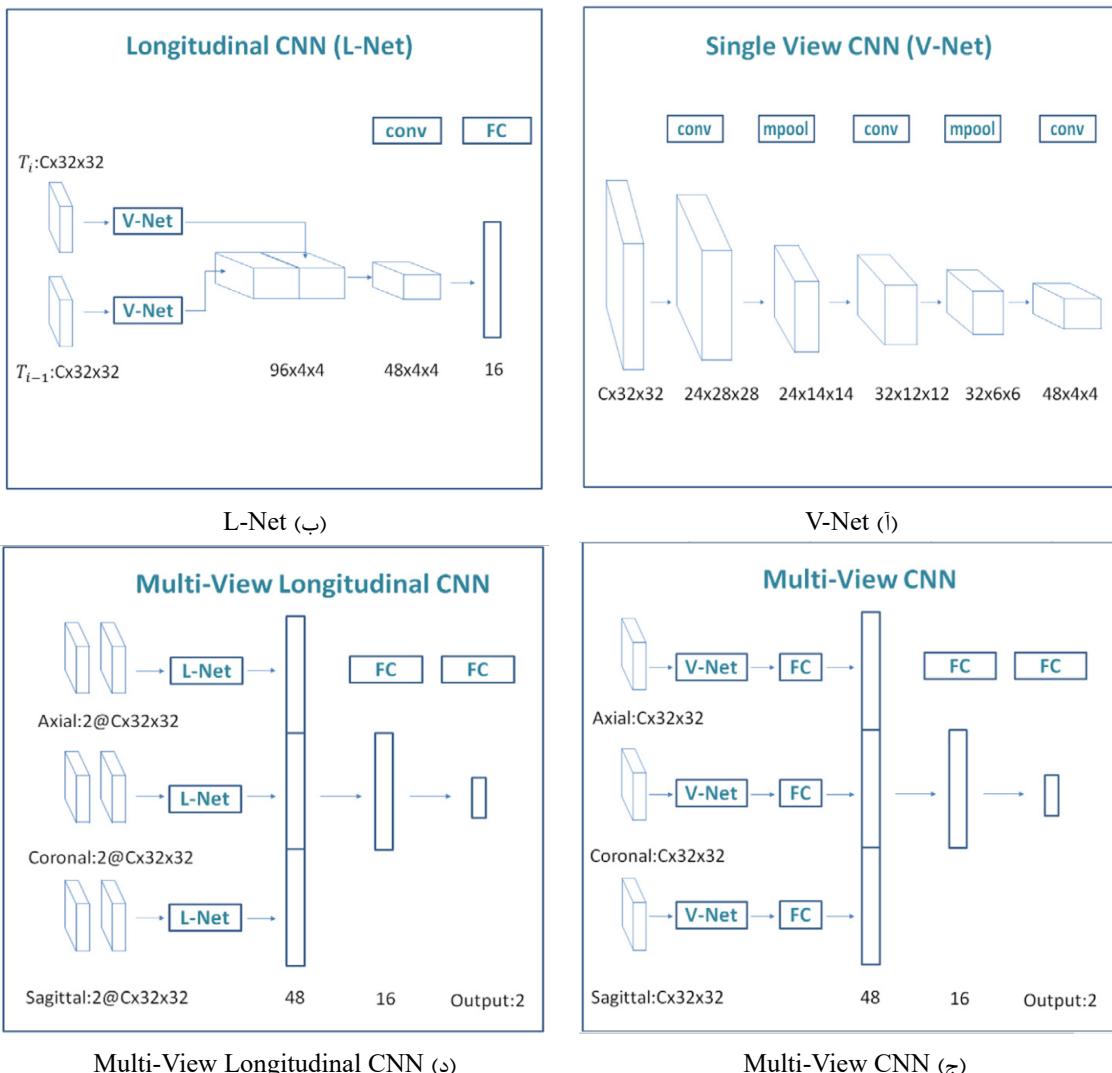
• فاز پیش بینی با استفاده از شبکه‌های کانولوشنی

استخراج نواحی کاندید برای ضایعه از مرحله قبل به عنوان ورودی این مرحله می‌باشد. خروجی این فاز یک ارزش احتمالی ضایعه برای هر واکسل از تصویر می‌باشد. با توجه به شکل ۱۱-۲ معماری‌های مختلفی از شبکه‌های کانولوشنی برای این عمل

^۱Hyperintense

^۲Cross Validation

وجود دارد. چهار نوع شبکه کانولوشنی وجود دارد که در شکل ۱۱-۲ می‌توان مشاهده کرد.



[۱۱-۲] شکل ۱۱-۲: شبکه‌های کانولوشنی استفاده شده در [۱۱]

در مقاله‌ای دیگر در سال ۲۰۱۷ قریبی^۱ و همکاران [۱۲] یک روش مبتنی بر شدت ارایه دادند. فلوچارت روش پیشنهادی در شکل

۱۲-۲ نشان داده شده است. همانطور که نمایش داده شده است این روش از چهار مرحله تشکیل شده است که در ادامه هر کدام از

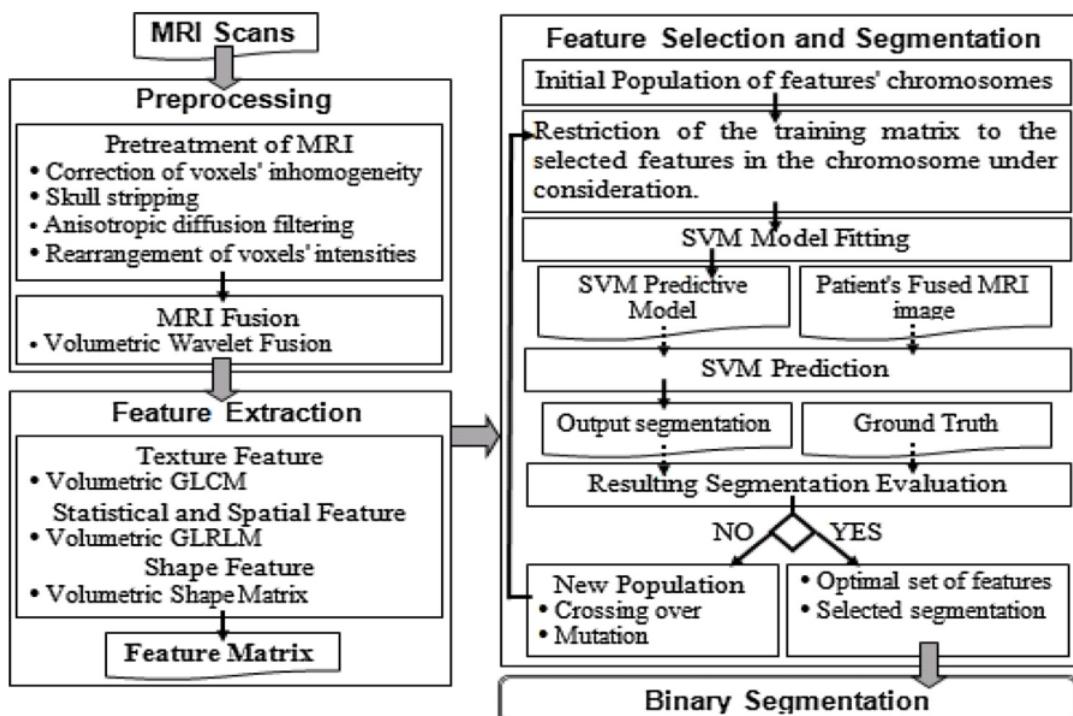
این مراحل به تفضیل شرح داده شده است.

- **پیش پردازش:** در این مرحله به دلیل یکنواخت ساختن سطوح روشنایی بافت‌ها ابتدا ناهمگنی شدت ناشی از میدان

مغناطیسی در تصاویر MRI رفع می‌شود سپس هر یک از تصاویر با استفاده از الگوریتم‌های موجود تطبیق داده شده‌اند و

بافت غیر از مغز از تصاویر حذف شده است. همچنین یک الگوریتم حذف نویز به تصاویر اعمال شده است. در نهایت سطوح

^۱Ghribi



[۱۲-۲]: فلوچارت روش پیشنهادی [۱۲]

روشنایی واکسل‌ها در یک محدوده یکسان تنظیم شدند.

- **ادغام تصویر^۱:** ادغام تصویر فرآیند ترکیب اطلاعات مربوطه از چندین عکس به یک تصویر واحد می‌باشد. انواع مختلف

ضایعه MS می‌تواند در حالت‌های مختلف MRI متفاوت باشد. ماهیت تصاویر T1-Weighted

ضایعه MS می‌تواند در حالی که FLAIR و T2-Weighted ضایعات را به عنوان مناطق با شدت روشنایی بالا نشان

می‌دهند. همچنین در تصاویر T1-Weighted با افزایش گادولینیم^۲ ضایعات فعال را به عنوان مناطق روشن نشان می‌دهد.

به منظور بررسی انواع مختلف ضایعات که در تصاویر مختلف ظاهر می‌شوند، در این مقاله پیشنهاد شده است با استفاده از

یک فرآیند ادغام ویولت^۳ تصاویر اسکن شده از یک شخص باهم ادغام کرده و در نتیجه ادامه روند کار فقط بر روی یک

تصویر واحد انجام می‌شود.

- **استخراج ویژگی:** در این مقاله از دو رویکرد استخراج ویژگی GLCM^۴ و GLRLM^۵ استفاده شده است که هر یک از

آن‌ها در ادامه توضیح داده خواهد شد.

^۱Image Fusion

^۲Gadolinium

^۳Volumetric Wavelet Fusion

^۴Volumetric Gray Level Co-occurrence Matrix

^۵Volumetric Gray-level Run Length Encoding Matrix

تکنیک GLCM ویژگی‌های بافت را از جمله اطلاعات مربوط به منظم بودن، ظرافت و زبری پیکسل‌های تصویر را استخراج می‌کند. این تکنیک در زمینه‌های مختلف مانند تجزیه و تحلیل تصاویر ماهواره‌ای، تصاویر پزشکی و بازیابی تصویر مفید می‌باشد. این روش اغلب همبستگی سطوح شدت را در چهار زاویه صفر، ۴۵، ۹۰، ۱۳۵ درجه محاسبه می‌کند. GLCM یک ماتریس مربعی $G(N \times N)$ است، جایی که N نشان دهنده تعداد سطوح خاکستری موجود در تصویر است. (i) تعداد هم رخدادی‌های سطوح خاکستری i و j است که در زاویه ϕ و فاصله d جدا شده‌اند. در این مقاله با استفاده از یک ماتریس GLCM به دنبال استخراج ویژگی‌های بافت مخفی از تصویر ادغام در مرحله قبل می‌باشد. برای این منظور از ۱۳ ϕ مستقل و چهار d در نظر گرفته شده است. سپس ویژگی‌های مرتبه اول شامل میانگین و واریانس استخراج شده و در نهایت ۱۶ ویژگی مرتبه دوم شامل انحراف، همبستگی، کتراست و ... با استفاده از این تکنیک استخراج شده است.

GLRLM این روش آماری و بافتی تعداد توالی نقاطی با سطح خاکستری مشخص را محاسبه می‌کند. $GLRLM(i, j | \theta)$ دنباله‌ای با j پیکسل که با سطح روشنای i در جهت θ تکرار شده‌اند را نشان می‌دهد. سپس تصویر ورودی را به بلاک‌های $4 \times 4 \times 4$ تقسیم کرده و برای هر یک از این بلاک‌ها ۱۳ ماتریس GLRLM با ۱۳ زاویه متفاوت استخراج شده است و در نهایت ۱۱ ویژگی آماری از هر یک از این ماتریس‌ها استخراج شده است. همچنین دو ویژگی مبتنی بر شکل از تصاویر استخراج می‌شود.

- **انتخاب ویژگی:** کیفیت تقسیم‌بندی به ویژگی‌های در نظر گرفته شده بستگی دارد. در این مقاله از الگوریتم ژنتیک به همراه ماشین بردار پشتیبان برای انتخاب ویژگی استفاده شده است.

در سال ۲۰۱۶ و همکاران [۱۳] یک رویکرد مبتنی بر طبقه‌بندی ارایه دادند برای این منظور هدف تقسیم‌بندی ضایعات را یافتن یکتابع s که تصویر ورودی را به یک تصویر دو سطحی تبدیل می‌کند تعریف کردند. در این رویکرد از یک شبکه‌های کانولوشنی^۱ استفاده شده است. برای آموزش این شبکه از یک مجموعه تصاویر آموزشی I_n و همچنین برچسب‌های متناظر با آن‌ها استفاده شده است. در نهایت مسئله تقسیم‌بندی ضایعات را به عنوان یک مسئله بهینه سازی به صورت زیر ارایه داده شده است:

$$\hat{s} = \arg \min_{s \in \mathcal{S}} \sum_n E(S_n, s(I_n)) \quad (25-2)$$

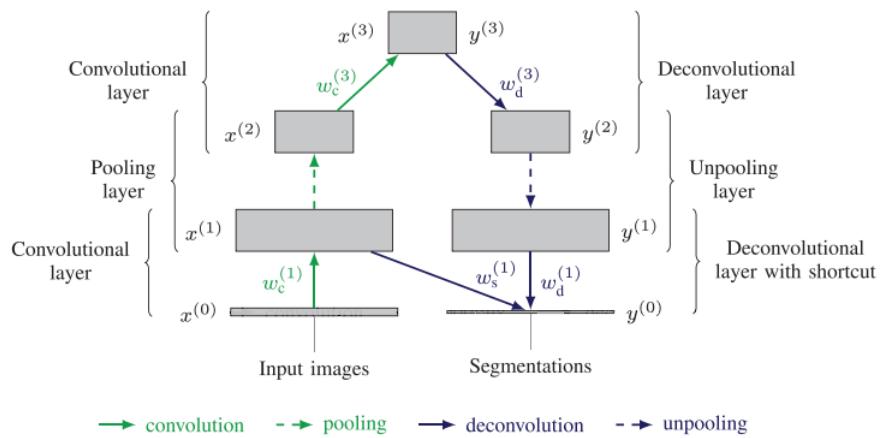
که در آن \mathcal{S} مجموعه ممکن از توابع تقسیم‌بندی می‌باشد و همچنین E یک معیار خطا برای محاسبه عدم شباهت بین نتیجه مطلوب^۲ و تقسیم‌بندی حاصل از تابع s در نظر گرفته می‌شود. که سعی در کمینه کردن این اختلاف می‌باشد تا به یک تابع

¹Convolutional Neural Network (CNN)

²Ground Truth

تقسیم‌بندی مناسب دست یابد.

معماری استفاده شده در این مقاله در شکل ۱۳-۲ نمایش داده شده است. همانطور که از تصویر مشخص می‌باشد ابتدا تصویر وردی را به صورت برداری $(\vec{p})^{(i)}$ که در آن i اندیس کanal تصویر وردی می‌باشد و همچنین $(\vec{p} \in \mathbb{N})$ معرف مختصات واکسل مورد نظر می‌باشد تبدیل کرده و سپس این بردار به عنوان وردی را به اولین لایه کانولوشن داده می‌شود و ویژگی‌های مورد نیاز به واسطه این لایه از شبکه از تصویر مورد نظر استخراج می‌شود. با توجه به معماری ارایه شده در شکل ۱۳-۲ این معماری شامل دو مسیر به



شکل ۱۳-۲: معماری پیشنهادی مقاله [۱۳]

هم پیوسته convolutional و deconvolutional می‌باشد.

مسیر از convolutional convolutional شامل دو نوع لایه convolutional و pooling می‌باشد. عملیات مربوط به لایه convolutional از طریق رابطه ۲۶-۲ محاسبه می‌شود.

$$x_j^{(l)} = \max \left(\cdot, \sum_{i=1}^C \hat{w}_{c,ij}^{(l)} * x_i^{(l-1)} + b_j^{(l)} \right) \quad (26-2)$$

که در آن l اندیس لایه convolutional $x_j^{(l)}, j \in [1, F]$ convolutional ویژگی‌های استخراج شده متناظر با فیلترهای قابل آموزش و F تعداد فیلترها در هر لایه convolutional convolutional، \hat{w} معرف وزن‌های فلیپ شده، $b_j^{(l)}$ معرف بایاس قابل آموزش و $*$ معرف عملیات کانولوشن می‌باشد. در این مسیر پس از هر لایه convolutional convolutional یک لایه pooling قرار می‌گیرد. این لایه شامل یک فیلتر میانگین با سایز $2 \times 2 \times 2 \times 2$ می‌باشد.

همچنین مسیر convolutional شامل دو نوع لایه deconvolutional و unpooling می‌باشد. عملیات مربوط به اولین لایه با استفاده از ویژگی‌های استخراج شده از مسیر convolutional از طریقه رابطه ۲۷-۲ محاسبه می‌شود.

$$y_j^{(L-1)} = \max \left(\cdot, \sum_{j=1}^F w_{d,ij}^{(L)} * y_i^{(L)} + c_j^{(L-1)} \right) \quad (27-2)$$

که در آن $y^L = x^L$ و L بیانگر تعداد لایه‌های مسیر convolutional می‌باشد همچنین $w_{d,ij}^{(L)}$ و $c_i^{(L-1)}$ به ترتیب بیانگر وزن و بایاس قبل آموزش و همچنین \circledast بیانگر عملیات کانولوشن کامل می‌باشند.

ماقی لایه‌های convolutional با استفاده از فعالیت لایه قبل و لایه convolutional متناظر با آن در مسیر convolutional باقی لایه‌های deconvolutional از طریقه رابطه ۲۸-۲ محاسبه می‌شود.

$$y_i^{(l)} = \max \left(\cdot, \sum_{j=1}^F w_{d,ij}^{(l+1)} \circledast y_j^{(l+1)} + \sum_{j=1}^F w_{s,ij}^{(l+1)} \circledast x_j^{(l+1)} + c_i^{(l)} \right) \quad (28-2)$$

که در آن l بیانگر شماره لایه deconvolutional و $w_{s,ij}^{(l+1)}$ ماسک مربوط به وزن‌ها می‌باشد. همچنین آخرین لایه convolutional و ویژگی‌های سطح پایین استخراج شده به وسیله اولین لایه convolutional و ویژگی‌های سطح بالای استخراج شده توسط لایه قبل را با یکدیگر ادغام کرده و ماسک احتمالاتی ضایعه را تولید می‌کند این روابط در رابطه ۲۹-۲ ارایه شده است.

$$y_i^{(\cdot)} = \text{sigm} \left(\sum_{j=1}^F \left(w_{d,ij}^{(\cdot)} \circledast y_j^{(\cdot)} + w_{s,ij}^{(\cdot)} \circledast x_j^{(\cdot)} \right) + c_i^{(\cdot)} \right) \quad (29-2)$$

که در آن $\text{sigm}(z)$ از رابطه ۳۰-۲ محاسبه شده و در نهایت برآورد نموده از روی مدل احتمالاتی خروجی یک آستانه ثابت برای آن در نظر گرفته شده است.

$$\text{sigm}(z) = \frac{1}{1 + \exp(-z)} \quad z \in \mathbb{R} \quad (30-2)$$

تا اینجا کار معماري روش پیشنهادی و روابط بین لایه‌های آن توضیح داده شد در ادامه برای بهینه سازی و بدست آوردن پارامترهای موثر روش آموزش شبکه توضیح داده خواهد شد.

پارامترهای مدل ارایه شده می‌توانند به صورت موثر با استفاده از کمینه کردن تابع خطا برای هر نمونه از مجموعه داده‌های آموزشی، آموزش داده شوند. برای این منظور از روش کاهش گرادیان استفاده شده است که در ادامه توضیح داده خواهد شد. عموماً در شبکه‌های عصبی فرایند آموزش با استفاده از کمینه کردن تابع هزینه SSD ^۱ که به صورت رابطه ۳۱-۲ تعریف می‌شود صورت

^۱ Sum of Squared Differences

می‌گیرد.

$$E = \frac{1}{2} \sum_{\vec{p}} \left(S(\vec{p}) - y^{(\cdot)}(\vec{p}) \right)^2 \quad (31-2)$$

که در آن $\vec{p} \in \mathbb{N}^*$ مختصات مربوط به پیکسل‌ها و S برچسب و همچنین $y^{(\cdot)}$ خروجی تولید شده با استفاده از شبکه مورد نظر می‌باشد.

برای بهینه سازیتابع خطابه می‌بایست ازتابع هزینه نسبت به پارامترها مشتقه جزیی را با استفاده از قانون دلتا محاسبه کرد روابطی که در ادامه بیان شده است مشتقه جزییتابع خطابه نسبت به پارامترها می‌باشد.

$$\frac{\partial E}{\partial w_{d,ij}^{(l)}} = \delta_{d,i}^{(l-1)} * \hat{y}_j^{(l)}, \quad \frac{\partial E}{\partial c_i^{(l)}} = \sum_{\vec{p}} \delta_{d,i}^{(l)}(\vec{p}) \quad (32-2)$$

$$\frac{\partial E}{\partial w_{s,ij}^{(l)}} = \delta_{d,i}^{(l-1)} * \hat{x}_j^{(l)} \quad (33-2)$$

$$\frac{\partial E}{\partial w_{c,ij}^{(l)}} = x_i^{(l-1)} * \hat{\delta}_{c,j}^{(l)}, \quad \frac{\partial E}{\partial b_i^{(l)}} = \sum_{\vec{p}} \delta_{c,i}^{(l)}(\vec{p}) \quad (34-2)$$

که در آن برای اولین لایه $\delta_{d,1}^{(\cdot)}$ به صورت زیر محاسبه می‌شود.

$$\delta_{d,1}^{(\cdot)} = (y_1^{(\cdot)} - S)y_1^{(\cdot)}(1 - y_1^{(\cdot)}) \quad (35-2)$$

همچنین برای دیگر لایه‌ها از رابطه زیر محاسبه می‌شود:

$$\delta_{d,j}^{(l)} = (\hat{w}_{d,ij}^{(l)} * \delta_{d,i}^{(l-1)}) \Gamma(y_j^{(l)} > \cdot) \quad (36-2)$$

$$\delta_{c,i}^{(l)} = (w_{c,ij}^{(l+1)} \circledast \delta_{c,j}^{(l+1)}) \Gamma(x_i^{(l)} > \cdot) \quad (37-2)$$

که در ان l شماره لایه $\delta_{c,i}^{(l)} = \delta_{d,j}^{(l)}$ و $\Gamma(z)$ بدین صورت تعریف می‌شود که اگر z درست باشد مقدار ۱ و در غیر این صورت مقدار ۰ را به خود می‌گیرد. همچنین $\delta_{c,j}^{(l)}$ از رابطه زیر بدست خواهد

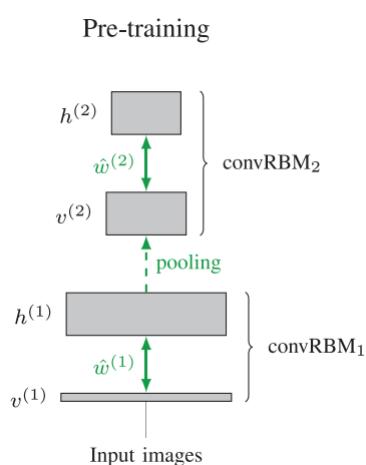
آمد:

$$\delta_{c,j}^{(l)} = (\delta_{c,j}^{(l)'} + \hat{w}_{s,ij}^{(l)} * \delta_{d,i}^{(l-1)}) \Gamma(x_j^{(l)} > \cdot) \quad (38-2)$$

در صورتی که دو کلاس نسبتاً متعادل باشند تابع خطای SDD یک معیاری مناسب برای سنجش دقّت مناسب در مسائل طبقه‌بندی می‌باشد. با این حال در صورت عدم متوازن بودن کلاس‌ها (مانند آنچه در تقسیم‌بندی ضایعه دیده می‌شود) معیار خطای تحت تاثیر کلاس اکثربت قرار گرفته و نمی‌تواند بیانگر دقّت طبقه‌بند باشد چرا که شبکه عصبی به سادگی نمونه‌های کلاس اقلیت را نادیده گرفته و همچنان معیار مذکور بر خلاف واقعیت نشان دهنده دقّت طبقه‌بند می‌باشد. برای غلبه بر این مشکل، در این مقاله از ترکیبی از حساسیت^۱ و تشخیص^۲ استفاده شده است که می‌تواند با هم برای اندازه گیری عملکرد طبقه‌بندی حتی برای مسایل بسیار نامتوازن استفاده شود. به بیانی دیگر، اندازه گیری خطای نهایی یک مجموع وزنی از میانگین مربع اختلاف واکسل‌های ضایعه (حساسیت) و واکسل‌های غیر ضایعه (تشخیص) می‌باشد، تابع خطای اصلاح شده به صورت زیر خواهد بود:

$$E = r \frac{\sum_{\vec{p}} \left(S(\vec{p}) - y^{(.)} \right)^2 S(\vec{p})}{\sum_{\vec{p}} S(\vec{p})} + (1 - r) \frac{\sum_{\vec{p}} \left(S(\vec{p}) - y^{(.)} \right)^2 S(1 - \vec{p})}{\sum_{\vec{p}} S(1 - \vec{p})} \quad (۳۹-۲)$$

نرخ حساسیت^۲ می‌تواند به منظور انتساب وزن‌های مختلف به دو ترم موجود در رابطه ۳۹-۲ استفاده شود. به دلیل تعداد زیاد واکسل‌های غیر ضایعه وزن دهی بالاتر به خطای تشخیص دارای اهمیت می‌باشد اما بر اساس نتایج تجربی اولیه الگوریتم نسبت به تغییرات^۲ ثابت بوده که خود شدیداً بر مقدار آستانه استفاده شده برای باینری کردن خروجی احتمالی اثر گذار می‌باشد. در نهایت می‌باشد شبکه پیشنهادی آموزش داده شود و مورد تست قرار بگیرد. در ابتدای دوره آموزشی، پارامترهای مدل باید ابتدا تنظیم شوند و مقدار دهی اولیه پارامترها می‌تواند تأثیر زیادی بر مدل داشته باشد. بنابراین در این مقاله از یک مدل برای پیش آموزش استفاده شده است که در شکل ۱۴-۲ قابل مشاهده می‌باشد در آزمایشات نویسنده‌گان متوجه شدن مقدار دهی اولیه مدل با



شکل ۱۴-۲: مدل ارایه شده برای پیش آموزش [۱۲]

^۱Sensitivity

^۲Specificity

استفاده از پیش آموزش بر روی تصاویر ورودی به منظور تنظیم دقیق‌تر مدل ضروری است. پیش آموزش می‌تواند به صورت لایه به لایه با استفاده از پشتۀ convRBM انجام شود. بدین صورت از مسله احتمالی انفجار یا کاهش گرادیان جلوگیری می‌شود. اولین convRBM بر روی تصاویر ورودی آموزش داده می‌شود و convRBM‌های بعدی بر روی مقدار خروجی convRBM قبلی آموزش می‌یابند. پس از آموزش تمام convRBM‌ها پارامترهای مدل می‌تواند به صورت زیر مقدار دهی اولیه شود:

$$w_c^{(1)} = \hat{w}^{(1)}, \quad w_d^{(1)} = \cdot / 5\hat{w}^{(1)}, \quad w_s^{(1)} = \cdot / 5\hat{w}^{(1)}, \quad b^{(1)} = \hat{b}^{(1)}, \quad c^{(\cdot)} = \hat{c}^{(1)} \quad (40-2)$$

که در آن $\hat{w}_c^{(1)}$ وزن‌های فیلتر و $\hat{b}^{(1)}$ ترم بایاس پنهان و $\hat{c}^{(1)}$ ترم بایاس آشکار از اولین convRBM است.

یکی از چالش‌های عمده برای روش‌های بهینه سازی مبتنی بر گرادیان، انتخاب یک نرخ یادگیری مناسب است. الگوریتم کلاسیک تصادفی شبیب نزولی^۱ از نرخ یادگیری ثابت یا کاهشی استفاده می‌کند که برای تمام پارامترهای مدل مشابه است. با این حال، مشتقات جزئی از پارامترهای لایه‌های مختلف می‌تواند به طور قابل توجهی در اندازه‌های مختلف متفاوت باشد، که می‌تواند نیاز به نرخ‌های مختلف یادگیری را ایجاد کند. در سال‌های اخیر، توسعه روش‌های انتخاب خودکار و مستقل نرخ یادگیری توجه فراوانی را به خود جلب کرده است. اکثر این روش‌ها مانند RMSprop، AdaDelta، AdaGrad آماره‌های مختلفی از مشتقات جزئی را بر روی چندین تکرار جمع آوری می‌کنند و از این اطلاعات برای تنظیم نرخ یادگیری سازگار برای هر پارامتر استفاده می‌کنند. این به ویژه برای آموزش شبکه‌های عمیق مهم است که در آن نرخ یادگیری مطلوب اغلب برای هر لایه متفاوت است. در آزمایش‌های اولیه این مقاله، شبکه‌های به دست آمده توسط آموزش با Adam، AdaDelta و RMSprop قوی ترین انتخابات برای hyperparameters بود، بنابراین از AdaDelta استفاده شده است.

در سال ۲۰۱۸ حیدری و همکاران یک روش مبتنی بر شدت ارایه دادند [۲۷]. در این مقاله در ابتدا برای حذف جمجه از تصاویر از BET الگوریتم استفاده شده است سپس روش‌های مختلف پردازش تصویر استفاده شده است، مانند تشخیص لبه و تقسیم بندی. در ابتدا یک الگوریتم لبه‌یابی برای استخراج لبه‌های تصویر بر روی آن اعمال کرده سپس برای تشخیص پلاک‌های بیماری از الگوریتم FCM استفاده شده است. علاوه بر این، برای افزایش دقت تشخیص و داشتن بهترین نتیجه، پارامترهای خوشبندی تعیین داده شده‌اند. در این مقالهتابع هزینه پیشنهادی برای خوشبندی FCM به صورت رابطه ۴۱-۲ می‌باشد که دارای دو ترم اضافه می‌باشد.

$$J = \sum_{j=1}^N \sum_{i=1}^c u_{ij}^m \|x_j - v_i\|^{\gamma} + a\alpha S + \beta R \quad (41-2)$$

^۱Classic stochastic gradient descent

که در آن S برای استفاده از تاثیر همسایگی در تقسیم بندی استفاده شده است و همچنین R یک ترم رگولاتور می‌باشد که برای حذف میدان بایاس اضافه شده است و این دو ترم به صورت زیر تعریف می‌شود.

$$J = \sum_{j=1}^N \sum_{i=1}^c u_{ij}^m \left(\frac{1}{N_\epsilon} \sum_{x \in N_\epsilon} \|x - v_i\|^r \right) \quad (42-2)$$

$$J = \sum_{j=1}^N \sum_{i=1}^c u_{ij}^m (\|\gamma_j\|^r) \quad (43-2)$$

که در آن ϵ همسایگی‌های پیکسل x می‌باشد. در ادامه با سعی در کمینه سازی اینتابع انرژی دارد. در اواخر سال ۲۰۱۸ الشیجیا و همکاران [۲۸] یک روش مبتنی بر شدت با استفاده از شبکه‌های عصبی ارایه دادند. این روش شامل سه مرحله می‌باشد.

- پیش پردازش در سال‌های اخیر همه‌ی کارهای انجام شده برای تقسیم‌بندی تصاویر MRI ابتدا بافت‌های غیر مغز نظیر

جمجمه، چربی، حذف ناهمگونی شدت حذف می‌شند و سپس الگوریتم تقسیم‌بندی بر روی آن‌ها اعمال می‌شود. هدف این

مقاله استفاده از تصاویر در فرمت اصلی خود می‌باشد. بدین منظور پیش پردازش‌های صورت گرفته شده متفاوت خواهد بود.

در ابتدا به منظور کاهش تفاوت بین تصاویر از الگوریتم تطبیق هیستوگرام استفاده شده است. سپس یک ماسک برای بدست

آوردن ناحیه هدف با تصویر AND شده و ناحیه هدف بدست آورده می‌شود. در مرحله بعد با استفاده از آستانه‌گذاری آتسو

^۱ تصویر را به یک تصویر دو سطحی تبدیل کرده و مکان‌های کاندید برای پیش‌بینی ضایعه بدست آورده می‌شوند در نهایت

با استفاده از عملگرهای مورفولوژی ناحیه‌های ریز از تصویر دو سطحی حذف می‌گردند.

- استخراج ویژگی در این مرحله ۱۵ ویژگی از تصویر استخراج می‌شود که در ادامه هر یک از ویژگی‌ها توضیح داده خواهد شد.

۱. مساحت: تعداد پیکسل‌های موجود در ناحیه

۲. میانگین سطوح خاکستری

۳. مرکز ۱: مختصات مرکز پلاک در راستای عمودی

۴. مرکز ۲: مختصات مرکز پلاک در راستای افقی

۵. جهت: زاویه بین راستای افقی و محور بزرگ بیضی

^۱Otsu's threshold

۶. طول محور اصلی (محور بزرگتر بیضی)
۷. طول محور فرعی (محور کوچکتر بیضی)
۸. مساحت کوچکترین ناحیه محدب ضایعه
۹. فرار از مرکز
۱۰. قطر دایره معادل که رابطه $ED = \sqrt{4 \times Area/pi}$ محاسبه می‌شود.
۱۱. نسبت مساحت ضایعه به مساحت ناحیه محدب آن
۱۲. نسبت تعداد پیکسل‌های ضایعه به تعداد پیکسل‌های ناحیه آن
۱۳. مقدار افقی مرکز توده بافت توخالی بر اساس شدت و مکان
۱۴. مقدار عمودی مرکز توده بافت توخالی بر اساس شدت و مکان
- شناسایی الگو در این مرحله می‌بایست با استفاده از الگوریتم‌های یادگیری و داده‌های موجود یک الگوی مشخص از این داده‌ها استخراج شود. برای این منظور از یک شبکه عصبی با یک لایه مخفی با ۱۸ نرون استفاده شده است و آموزش داده شده است.

در جدول ۱-۲ مزایا و معایب روش‌های مبتنی بر شدت ارایه شده است.

۳-۴-۲ روش‌های مبتنی بر اطلس

اگر یک اطلس یا الگو مغز انسان برای یک جمعیت خاص مورد علاقه در دسترس باشد، روش‌های مبتنی بر اطلس می‌تواند یک ابزار قدرتمند برای تقسیم بندی تصاویر MRI مغز باشد. این اطلس حاوی اطلاعات مربوط به آناتومی مغز است (به عنوان مثال، حاوی اطلاعاتی در مورد مکان ساختارهای متفاوت مغز است) و به عنوان یک مرجع (اطلاعات قبلی) برای جداسازی تصاویر جدید استفاده می‌شود. مزیت اصلی این روش‌ها امکان تقسیم هر ساختار مغزی موجود در اطلس بدون هزینه اضافی است. به طور مفهومی، روش‌های مبتنی بر اطلس شبیه به روش‌های طبقه بندی می‌باشد، با این تفاوت که روش‌های مبتنی بر اطلس در حوزه مکان می‌باشند و لی روش‌های مبتنی بر طبقه بندی از فضای ویژگی استفاده می‌کنند [۵].

قبل از اینکه یک اطلس بتواند به عنوان یک دانش پیشین^۱ مورد استفاده قرار گیرد، باید با تصویری که تقسیم بندی بر روی آن انجام

^۱prior knowledge

جدول ۲-۱: مزایا و معایب روش‌های مبتنی بر شدت

معایب	مزایا	
۱. به دلیل عدم توجه به اطلاعات همسایگی بسیار حساس به نویز می‌باشد. ۲. دقت پایین	۱. روش ساده ۲. دارای پیچیدگی محاسباتی پایین	آستانه گذاری
۱. زمان زیاد برای آموزش ۲. احتمال بیش برآش ۳. نیاز به داده‌های اولیه زیاد برای آموزش ۴. حساسیت بیشتری نسبت به تغییر شکل ظاهری ضایعات	۱. مدل‌های زیاد طبقه‌بندی زیاد برای استفاده موجود می‌باشد. ۲. دارای دقت بالایی در مرحله آموزش می‌باشد. ۳. مقاوم در برابر نویز	طبقه‌بندی با نظارت
۱. دشوار بودن برای رسیدن به دقت بالا ۲. تولید نقاط مثبت کاذب ^۱	۱. دارای سرعت بالا ۲. نیاز نداشتن به داده برای آموزش ۳. مقاوم در برابر نویز	طبقه‌بندی بدون نظارت

می‌شود، هم تراز و تطبیق داده شوند. بنابراین، عملکرد روش‌های مبتنی بر اطلس مستقیماً بستگی به کیفیت روش تطبیق دارد.

روندهای مبتنی بر اطلس در شکل ۲-۱۵ نمایش داده شده است.

در سال ۲۰۱۵ جین^۱ و همکاران^[۱۴] یک رویکرد مبتنی بر اطلس به نام MSmetrix پیشنهاد دادند. فلوچارت این روش در

شکل ۲-۱۶ قابل مشاهده می‌باشد. در این روش ابتدا دو تصویر T1-Weighted و همچنین FLAIR را به عنوان ورودی دریافت

کرده و پس از طی کردن مراحل پیش پردازش وارد مرحله اصلی تشخیص ضایعه بیماری می‌شود که در ادامه هر یک از این مراحل

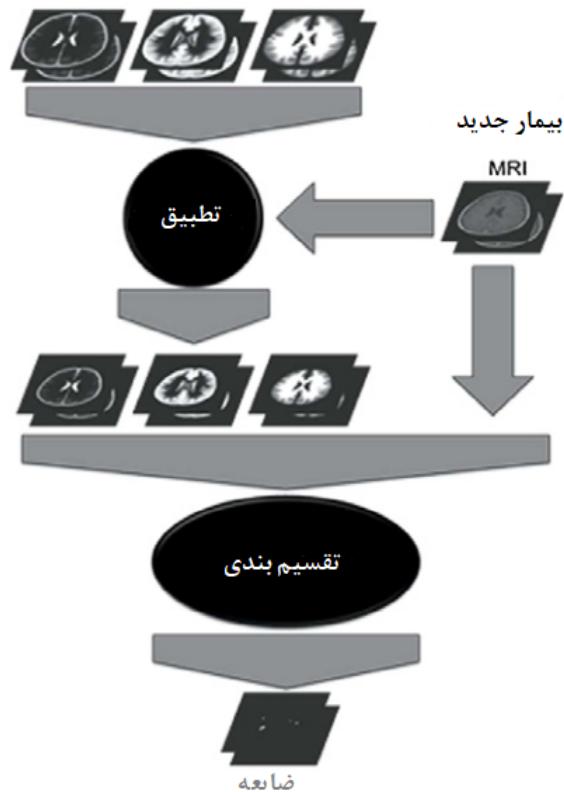
به تفضیل شرح داده شده است.

• مرحله پیش پردازش: این مرحله دارای سه بخش زیر می‌باشد:

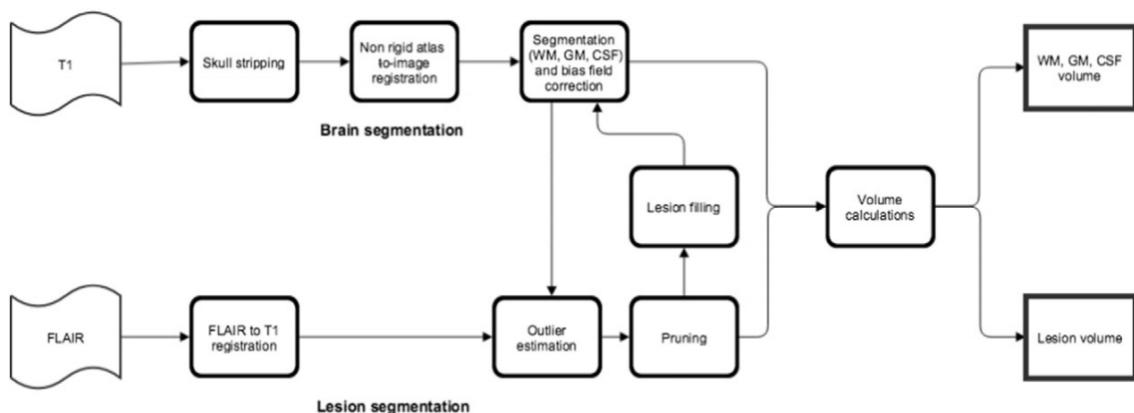
- در بخش اول تصویر FLAIR از بیمار با تصویر T1-w با استفاده از معیار شباهت ضربی همبستگی^۲ متقابل نرمال

^۱Jain

^۲Normalised Cross Correlation



شکل ۱۵-۲: فلوچارت روش‌های مبتنی بر اطلس [۵]



شکل ۱۶-۲: فلوچارت روش پیشنهادی [۱۴]

با استفاده از تبدیل سخت^۱ تطبیق داده می‌شوند.

۲. در بخش دوم با استفاده از الگوریتم‌های موجود واکسل‌هایی که مربوط به بخش جمجمه سر می‌شوند از تصویر حذف می‌شود. که این بخش با استفاده از تطبیق تصویر مورد نظر با ماسک مغز موجود برای تصاویر دیتاست مورد نظر انجام می‌گیرد.

^۱Rigid

۳. در بخش سوم دانش آناتومی قبلی در مورد بافت‌های مغز (CSF و WM.GM) با استفاده از تبدیل affine با تصویر

T1-w که در بخش قبلی بافت غیر مغز از آن سلب گردید تطبیق داده می‌شود.

• مرحله قطعه بندی اولیه: در این مرحله یک مدل احتمالاتی برای تقسیم بندی کردن تصویر T1-Weighted (که در

مرحله قبل بافت‌های غیر مغز آن حذف شده است) که براساس دانش پیشین داده شده توسط بافت‌های احتمالی، طراحی

شده است. بدین صورت که پس از تطبیق تصویر مورد نظر با اطلس‌های موجود با استفاده از الگوریتم EM سعی در بهینه

کردن پارامترهای مربوط به هر بافت از کلاس و همچنین حذف میدان بایاس از تصاویر می‌باشد. پس از همگرا شدن الگوریتم

تصویر EM خروجی هم میدان بایاس آن رفع شده است و هم یک تقسیم بندی اولیه انجام شده است.

• مرحله تخمین ضایعات:

در این مرحله با استفاده از تقسیم بندی اولیه مرحله قبل به عنوان دانش اولیه والگوریتم EM سعی در تخمین ضایعات

مغزی می‌باشد. بدین صورت که با توجه به تقسیم بندی انجام شده در مرحله قبل بر روی تصویر T1-Weighted، سطوح

خاکستری هر کلاس بافت در تصویر FLAIR به عنوان یک توزیع نرمال مدل می‌شود و در ادامه انحراف هر واکسل از

تصویر FLAIR از این مدل به عنوان نقشه نادرست تخمین زده می‌شود. این نقشه به صورت تکراری در هر مرحله به وسیله

الگوریتم EM به روز رسانی می‌شود در نهایت میدان بایاس و همچنین بافت‌های ضایعه در تصویر FLAIR تخمین زده

می‌شود. این تصویر نقشه به عنوان یک مقدار دهی اولیه برای تقسیم بندی ضایعه MS در مرحله بعد استفاده می‌شود.

• مرحله هرس کردن:

تا این مرحله از کار ضایعات تخمین زده اند اما لزوماً تمامی واکسل‌های تخمین زده ضایعه نمی‌باشند بنابراین باید

بعضی از واکسل‌های تخمین زده شده به اصطلاح هرس شوند. برای جدای کردن واکسل‌های ضایعه از واکسل‌های غیر ضایعه

نیاز به اطلاعات اضافی در مورد مکان و ظاهر واکسل‌ها می‌باشد.

○ اطلاعات مکانی واکسل‌های ضایعه

ضایعه‌ها باید در منطقه WM باشند.

○ اطلاعات ظاهری واکسل‌های ضایعه

واکسل‌های ضایعه در مقایسه با واکسل‌های GM دارای شدت بالاتری (hyperintensity) می‌باشند که این ویژگی

با یک آستانه گذاری ساده تعریف می‌شود. آستانه مورد نظر برابر با میانگین به اضافه دو برابر انحراف معیار سطوح

خاکستری بافت GM در نظر گرفته می‌شود. (در تصویر FLAIR تصحیح شده)

• مرحله پر کردن^۱ ضایعه: در این مرحله از تقسیم بندی ضایعه مرحله قبل برای پر کردن ضایعه در تصویر تصحیح شده

استفاده می‌شود. روش مورد استفاده شده برای پر کردن ضایعه در این مقاله بسیار مشابه روش LEAP

می‌باشد که در آن ابتدا میانگین و انحراف معیار سطوح خاکستری مربوط به بافت WM با استفاده از تقسیم بندی بافت

WM در مرحله دوم محاسبه می‌شود. از آنجایی که روش استفاده شده برای تقسیم بندی یک تقسیم بندی نرم می‌باشد

بنابراین اگر تصویر تقسیم بندی شده را با آستانه گذاری شود در این صورت می‌توان اطمینان کرد که تنها بافت

WM در آن گنجانده می‌شود. در نهایت پس از تشخیص واکسل‌های مربوط به ضایعه می‌بایست نواحی به صورت حفره پر

شوند. برای این عمل از یک کرنل گوسی با شعاع ۱ واکسل استفاده شده است.

در نهایت مراحل دوم تا پنجم تکرار می‌شوند تا تغییرات قابل توجهی در بافت و تقسیم بندی ضایعه وجود نداشته باشد.

مزایا و معایب این دسته از روش‌ها در جدول ۲-۲ قابل مشاهده می‌باشد.

جدول ۲-۲: مزایا و معایب روش‌های مبتنی بر اطلس

معایب	مزایا
۱. نیاز به یک مرحله پیش پردازش برای تطبیق می‌باشد و به همین دلیل عملکرد الگوریتم تطبیق تاثیر مستقیم بر روی عملکرد سیستم می‌گذارد.	۱. اگر یک اطلس مناسب وجود داشته باشد می‌تواند دقیق خوبی داشته باشد ۲. از آنجایی که از اطلاعات مکانی استفاده می‌کند حساس به نویز نمی‌باشد.

۴-۴-۲ روش‌های مبتنی بر رویه

علاوه بر روش‌های مبتنی بر شدت و مبتنی بر اطلس، تعدادی از روش‌های تقسیم بندی MRI مغز وجود دارد که به مدل‌های مبتنی

بر رویه (مدل‌های فرم پذیر) معروف می‌باشند که به دو دسته پارامتری و هندسی تقسیم می‌شوند. مدل‌های فرم پذیر که همچنین

مرزهای فعال یا مدل مارها در دو بعد و همچنین سطوح فعال یا مدل بالن در سه بعد نامیده می‌شوند [۷].

^۱Fill

مدل‌های فرم پذیر برای اولین بار توسط آقای kass در فضای دو بعدی معرفی شد و بعد از آن این مدل‌ها به فضای سه بعدی توسعه داده شد. مدل‌های فرم پذیر از منحنی‌های پارامتری بسته (در فضای دو بعدی) و یا سطوح پارامتری (در فضای سه بعدی) بسته برای تعریف مرزهای ناحیه استفاده می‌کنند. منحنی‌ها و سطوح پارامتریک تحت تاثیر نیروهای خارجی (کنترل شده توسط ویژگی‌های تصویر) و نیروهای داخلی (نظم سطح را کنترل می‌کنند)، تغییر می‌کنند [۷]. برای تعریف یک مرز از یک جسم، یک منحنی بسته یا سطح S در نزدیکی مرز مورد نظر در یک تصویر قرار می‌گیرد. سپس، نیروهای داخلی و خارجی، در یک فرآیند تکراری و به صورت نرم سعی در تغییر شکل منحنی دارد. تابع انرژی به صورت زیر تعریف می‌شود:

$$F(S) = F_{int} + F_{ext} \quad (44-2)$$

که در آن نیروهای داخلی F_{int} از اطلاعات مربوط به منحنی یا سطح محاسبه می‌شوند تا در طول تغییر شکل منحنی صاف و مشتق پذیر نگه داشته شوند. همچنین نیروهای خارجی F_{ext} معمولاً از اطلاعات تصویر به منظور تغییر شکل منحنی و یا سطح به سمت ویژگی مورد نظر موردنظر محاسبه می‌شوند [۷]. در مدل‌های قدیمی مرزهای فعال، نیروهای تصویر عمدها از اطلاعات مبتنی بر لبه استفاده می‌کردند. با این وجود، این وابستگی به اطلاعات لبه باعث می‌شود که مدل‌های فرم پذیر بسیار حساس به نویز و به شدت وابسته به تعریف منحنی اولیه در تصویر می‌باشد [۷].

همان‌طور که بیان شد مدل‌های فرم پذیر به دو دسته تقسیم می‌شوند: مدل‌های پارامتری و مدل‌های هندسی. مرز اولیه در مدل‌های پارامتری به صورت صریح بیان می‌شود در صورتی که در مدل‌های هندسی به صورت ضمنی بیان می‌شود. مراحل کلی قطعه‌بندی به روش مدل فرم پذیر هندسی توسط نمایش ضمنی و تکامل منحنی با استفاده از روش سطح تراز، شامل موارد زیر است:

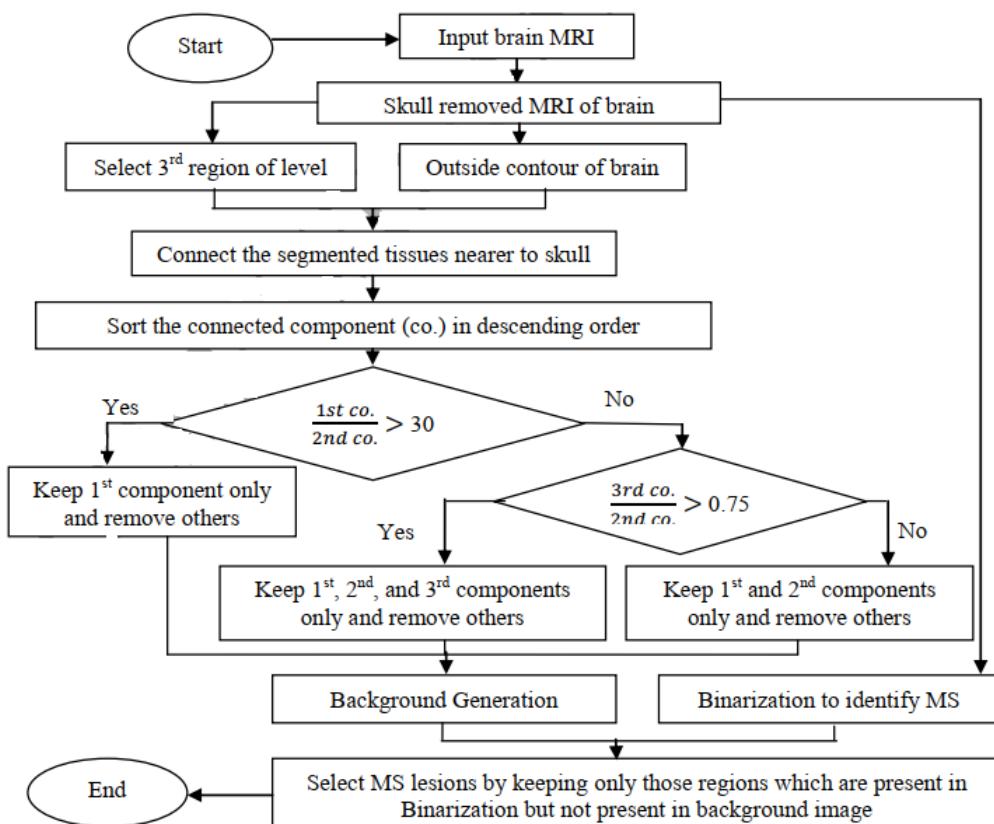
۱. مقداردهی اولیه منحنی
۲. نمایش مرز مشترک با استفاده از یک تابع ضمنی با بعد بالاتر
۳. تنظیم سرعت تغییر شکل بر اساس داده‌های تصویر (ابتدا سرعت زیاد است، با نزدیکی به لبه‌ها و مرزهای شی سرعت کاهش پیدا کرده و با رسیدن به مرزهای شی مورد نظر سرعت صفر می‌شود).
۴. تکامل منحنی تا همگرایی و پایداری منحنی (توقف تکامل در مرزهای شی)

در ادامه به بررسی مقالات موجود در این زمینه پرداخته خواهد شد و جریایت هر یک از این مقالات مورد بررسی قرار

می‌گیرد.

در سال ۲۰۱۷ Roy و همکاران [۱۵] رویکردی مبتنی بر رویه ارایه کردند. شماهی کلی این روش پیشنهادی در شکل ۱۷-۲ قابل

مشاهده می‌باشد. کل روش پیشنهادی به صورت گام به گام در شکل ۱۷-۲ نشان داده شده است. جزئیات بخش‌بندی، ساختن مرز



شکل ۱۷-۲: فلوچارت روش پیشنهادی [۱۵]

و انتخاب مولفه متصل به عنوان مراحل میانی برای تولید پس زمینه در مرحله اول توضیح داده شده است. در مرحله تولید پس زمینه

خروجی حاوی برخی از بافت‌های نرمال است، اما هیچ ضایعات MS وجود ندارد. رویکرد پیشنهادی برای شناسایی ضایعات MS

استفاده از یک الگوریتم تبدیل دودویی می‌باشد که در بخش دوم توضیح داده شده است. تبدیل دودویی با استفاده از یک آستانه،

ضایعات MS را با چندین بافت طبیعی دیگر به عنوان خروجی می‌دهد. در نهایت، آن دسته از مناطقی که در تبدیل دودویی وجود

دارند ولی در تصویر پس زمینه موجود نمی‌باشند به عنوان ضایعات MS در نظر گرفته می‌شود.

در سال ۲۰۱۷ Zhao و همکاران [۲۹] مقاله‌ای مبتنی بر رویه ارایه داده که این مقاله توسعه یافته روش MICO [۱۰] می‌باشد.

در این مقاله ابتدا پیش‌پردازش‌های حذف جمجه، چربی، پوست صورت می‌گیرد سپس رویکرد پیشنهادی برای تقسیم بندی روی

تصاویر صورت می‌گیرد.

رویکرد پیشنهادی این مقاله برای تخمین بایاس و همچنین قطعه بندی بافت و ضایعات مبتنی بر تجزیه تصویر MRI به دو جز

ضرب شونده می‌باشد که در رابطه زیر نمایش داده شده است:

$$I(x) = b(x)J(x) + n(x) \quad (45-2)$$

که در آن $I(x)$ مقدار سطح روشنایی در واکسل (x) ، $J(x)$ مقدار سطح روشنایی تصویر عاری از میدان بایاس (تصویر درست)،

$b(x)$ میدان بایاس موجود در تصویر مشاهده شده و همچنین $n(x)$ یک نویز جمع شونده با میانگین صفر می‌باشد.

مدل تشکیل تصویر MRI بالا می‌تواند به طور طبیعی به تصاویر چند کanalه MRI گسترش یابد. تصاویر MRI چند کanalه به عنوان

یک بردار به صورت رابطه ۴۶-۲ نمایش داده می‌شود.

$$\mathbf{I}(x) = (I_1(x), \dots, I_L(x))^T \quad (46-2)$$

که در آن L مشخص کننده تعداد کanalها می‌باشد. در این مقاله تنها از دو تصویر T1-Weighted و FLAIR استفاده شده است

بنابرای تعداد کanalها برابر با دو در نظر گرفته شده است.

با توجه به مدل شکل‌گیری تصویر MRI و همچنین تصاویر چند کanalه بنابراین می‌توان مدل شکل‌گیری تصاویر MRI را به صورت

رابطه ۴۷-۲ بسط داد.

$$I_i(x) = b_i(x)J_i(x) + n_i(x), \quad i = 1, \dots, L \quad (47-2)$$

که در آن b_i و n_i به ترتیب نشان دهنده میدان بایاس، تصویر درست و نویز مربوط به کanal i می‌باشد.

تصویر واقعی $J_i(x)$ خصوصیات فیزیکی بافت‌هایی که در حال تصویر برداری هستند را مشخص می‌کند، که به طور ایده آل برای

واکسل‌هایی که درون یک نوع نوع بافت قرار می‌گیرند، ارزش خاصی دارند. بنابراین، فرض شده است که $J_i(x)$ تقریباً یک ثابت

برای تمام نقاط x در بافت i است. بنابراین می‌توان رابطه ۴۸-۲ را برای تصویر $J_i(x)$ نوشت.

$$J_i(x) = \sum_{j=1}^N c_{i,j} u_j(x) \quad (48-2)$$

که در آن $u_j(x)$ نشان دهندهتابع تعلق می‌باشد و به صورت زیر تعریف می‌شود.

$$u_j(x) = \begin{cases} 1 & x \in \Omega_j \\ 0 & x \notin \Omega_j \end{cases} \quad (49-2)$$

همچنین همانطور که در مقاله [۱۰] بررسی شده است تابع $b_i(x)$ را می‌توان با استفاده از ترکیب خطی توابع پایه با دقت بالایی تقریب زد. بنابراین در این مقاله نیز برای تقریب تابع $b_i(x)$ از ترکیب خطی M توابع پایه $g_1(x), \dots, g_M(x)$ با ضرایب $w_{i,1}, \dots, w_{i,M}$ استفاده شده است. در این مقاله تعداد توابع پایه استفاده شده $M = 20$ می‌باشد.

$$b_i(x) = \sum_{j=1}^M w_{i,j} g_j(x) \quad (50-2)$$

در نهایت تابع هزینه معرفی شده در این مقاله برای یک کاتال از تصویر به صورت زیر می‌باشد:

$$F_i(\mathbf{u}, \mathbf{c}_i, \mathbf{w}_i) = \sum_{j=1}^N \int_{\Omega} |I_i(x) - W_i^T G(x) c_{i,j}|^\gamma u_i(x) dx \quad (51-2)$$

که از آن می‌توان نتیجه گرفت که تابع هزینه کلی به صورت زیر تعریف می‌شود:

$$F_i(\mathbf{u}, \mathbf{c}, \mathbf{w}) = \sum_{i=1}^L \lambda_i F_i(\mathbf{u}, \mathbf{c}_i, \mathbf{w}_i) \quad (52-2)$$

در نتیجه برای بهینه سازی تابع هزینه پیشنهادی می‌بایست از آن نسبت به پارامترها مشتق گرفت و برابر با صفر قرار داد. در ادامه روابط بهینه سازی هر یک از متغیرها توضیح داده خواهد شد.

رابطه بهینه سازی تابع عضویت $u_j(x)$ به صورت رابطه ۵۳-۲ می‌باشد.

$$\hat{u}_j(x) = \begin{cases} 1 & j = \arg \min_j (\delta_j(x)) \\ \cdot & j \neq \arg \min_j (\delta_j(x)) \end{cases} \quad (53-2)$$

که در آن $\delta_j(x)$ به صورت زیر تعریف می‌شود.

$$\delta_j(x) = \sum_{j=1}^L \lambda_j |I_i(x) - W_i^T G(x) c_{i,j}|^\gamma \quad (54-2)$$

همچنین روابط بهینه سازی مربوط به $c_{i,j}$ و $b_i(x)$ به صورت روابط زیر می‌باشد.

$$\hat{b}_i(x) = \mathbf{w}_i^t G(x) \quad (55-2)$$

$$\hat{c}_{i,j} = \frac{\int_{\Omega} I_i(x) u_j(x) dx}{\int_{\Omega} u_j(x) dx} \quad (56-2)$$

در نهایت قانون آپدیت w را می‌توان به صورت زیر نوشت.

$$W = \left(\int_{\Omega} G(x) G^T(x) \left(\sum_{i=1}^N c_i u_i(x) \right) dx \right)^{-1} G(x) I(x) \left(\sum_{i=1}^N c_i u_i(x) \right) dx \quad (57-2)$$

به طور خلاصه می‌توان الگوریتم پیشنهادی به صورت زیر نوشت:

• مرحله اول: مقدار دهی اولیه c و u

• مرحله دوم: محاسبه b طبق رابطه ۵۵-۲

• مرحله سوم: به روزرسانی c طبق رابطه ۵۶-۲

• مرحله چهارم: به روزرسانی u طبق رابطه ۵۳-۲

• مرحله پنجم: چک کردن شرط همگرایی اگر شرط همگرایی برآورده نشده بود به مرحله ۲ برو.

در مقاله ای دیگر در سال ۲۰۱۸ ژانو^۱ و همکاران [۳۰] یک روش مبتنی بر رویه معرفی کردند که روش پیشنهاد شده شامل یک مرحله اولیه برای پیش پردازش تصاویر اصلی و دو مرحله برای تقسیم‌بندی می‌باشد. در مرحله پیش پردازش ابتدا تصاویر ورودی T1-Weighted و FLAIR سلب جمجه شده و سپس هر یک از این دو تصاویر با یکدیگر تطبیق داده می‌شوند. پس از پیش پردازش تصاویر، یک بخش بندی اولیه انجام داده شده است در حالی که روش استفاده شده برای بخش بندی اولیه قدرتمند می‌باشد اما دارای دقت زیادی نمی‌باشد. در رویکرد پیشنهادی مقاله، تصویر FLAIR را به عنوان ورودی دریافت می‌کند و سپس یک تقسیم‌بندی اولیه بر روی انواع بافت مغز نظیر ماده سفید، ماده خاکستری و مایع مغزی نخاعی انجام می‌دهد و در نهایت یک رویکرد سطح تراز بر روی تصویر FLAIR ورودی اعمال کرده و نتیجه تقسیم‌بندی اولیه را بهبود می‌دهد. روش سطح تراز پیشنهادی بر اساس فرض ساخت تصویر MRI در رابطه ۵۸-۲ استوار است. در این روش همزمان حذف میدان بایاس و تقسیم‌بندی صورت می‌گیرد.

$$I(x) = b(x)J(x) + n(x) \quad (58-2)$$

که در آن $I(x)$ مقدار سطح روشنایی در واکسل $(x, J(x))$ ، $n(x)$ مقدار سطح روشنایی تصویر عاری از میدان بایاس (تصویر درست)، $b(x)$ میدان بایاس موجود در تصویر مشاهده شده و همچنین $n(x)$ یک نویز گوسی با میانگین صفر می‌باشد. از آنجایی که شدت روشنایی ماده سفید و ماده خاکستری در تصویر FLAIR نزدیک به یکدیگر و همچنین فاصله بین این دو بافت بسیار ضعیف می‌باشد بنابراین در این مقاله فرض شده است که تصاویر به سه بخش مایع مغزی نخاعی و پس زمینه تصویر، بافت نرمال (شامل ماده سفید و خاکستری) و ضایعات MS تقسیم‌بندی می‌شوند که هر یک از این بخش‌ها با نمادهای Ω_1 و Ω_2 نمایش داده می‌شوند.

¹Zhao

روش پیشنهادی مقاله بدین صورت می‌باشد که ابتدا برای هر پیکسل یک همسایگی مشخص می‌کند و این همسایگی می‌تواند شامل سه بخش باشد بنابراین برای بدست آوردن مجھولات می‌بایست رابطه ۵۹-۲ را کمینه کرد.

$$\mathcal{E}_x(\Omega_1, \Omega_2, \Omega_3, b(x), c_1, c_2, c_3) = \sum_{i=1}^3 \int_{\Omega_i} K_\sigma(x-y) |I(y) - b(x)c_i|^r dy \quad (59-2)$$

که در آن $K_\sigma(x-y)$ یک فیلتر گوسی می‌باشد. بنابراین باید تابع انرژی پیشنهاد شده برای تمامی پیکسل‌ها کمینه شود که این عمل از طریق کمینه سازی تابع ۶۰-۲ بدست خواهد آمد.

$$\begin{aligned} \mathcal{E}(\Omega_1, \Omega_2, \Omega_3, b(x), c_1, c_2, c_3) &= \int_{\Omega} \mathcal{E}_x(\Omega_1, \Omega_2, \Omega_3, b(x), c_1, c_2, c_3) \\ &= \sum_{i=1}^3 \int_{\Omega} \int_{\Omega_i} K_\sigma(x-y) |I(y) - b(x)c_i|^r dy \end{aligned} \quad (60-2)$$

سه ناحیه Ω_1 , Ω_2 و Ω_3 را می‌توان با سه تابع سطح تراز به صورت زیر نمایش داد.

$$M_1(\phi_1, \phi_2) = H(\phi_1) \quad (61-2)$$

$$M_2(\phi_1, \phi_2) = (1 - H(\phi_1))H(\phi_2) \quad (62-2)$$

$$M_3(\phi_1, \phi_2) = (1 - H(\phi_1))(1 - H(\phi_2)) \quad (63-2)$$

بنابراین می‌توان تابع هزینه پیشنهادی را با استفاده از تابع سطح تراز به صورت زیر بیان کرد:

$$\mathcal{E}(\Omega_1, \Omega_2, \Omega_3, b(x), c_1, c_2, c_3) =$$

$$\sum_{i=1}^3 \int_{\Omega} \int_{\Omega} K_\sigma(x-y) |I(y) - b(x)c_i|^r M_i(\phi_1(y), \phi_2(y)) dy dx \quad (64-2)$$

در نهایت می‌توان یک ترم رگولاتور به تابع هزینه پیشنهادی اضافه کرد که نتیجه حاصل به صورت رابطه زیر خواهد شد:

$$\mathcal{F}(\phi_1, \phi_2) = \mathcal{E}(\phi_1, \phi_2, b, c_1, c_2, c_3) + R(\phi_1, \phi_2) \quad (65-2)$$

با توجه به این که بهینه سازی با دو تابع سطح تراز ϕ_1 و ϕ_2 انجام می‌شود، همچنین تابع سطح تراز ϕ برای ناحیه بین ناحیه Ω_1 و Ω_2 (ناحیه بین مایع مغزی نخاعی و پس زمینه) استفاده شده است و از آنجایی که این مقاله فقط بر روی ضایعاتی که در ناحیه Ω_2 و Ω_3 می‌باشد، متمرکز شده است بنابراین نیاز به تابع سطح تراز اولی نمی‌باشد و مقدار آن را برابر با یک عدد ثابت در نظر گرفته شده است. با این فرضیات ترم رگولاتور را می‌توان به صورت رابطه ۶۶-۲ تعریف کرد.

$$R(\phi_2) = \gamma \int |\nabla H(\phi_2(y))| dy + \mu \int \frac{1}{2} (|\nabla \phi_2(y)| - 1)^2 dy \quad (66-2)$$

سپس برای کمینه سازیتابع انرژی نسبت به پارامترها مشتق گرفته شده و برابر با صفر قرار داده می‌شوند. در ابتدا از تابع انرژی

نسبت به پارامتر b مشتق گرفته شده که نتیجه حاصل به صورت زیر می‌شود.

$$\frac{\partial \mathcal{F}(\phi_1, \phi_2, b, c_1, c_2, c_3)}{\partial b} = . \quad (67-2)$$

که از آن می‌توان رابطه ۶۸-۲ را نتیجه گرفت.

$$\hat{b} = \frac{(I \sum_{i=1}^N c_i M_i(\phi_1, \phi_2) * K_\sigma)}{\sum_{i=1}^N c_i M_i(\phi_1, \phi_2) * K_\sigma} \quad (68-2)$$

در نهایت با نوشتن معادله اویلر لاغرانژ برای تابع انرژی پیشنهادی می‌توان رابطه زیر را بدست آورد.

$$c_i = \frac{\int (b * K) I M_i(\phi_1, \phi_2) dx}{\int (b * K) M_i(\phi_1, \phi_2) dx} \quad (69-2)$$

جدول ۳-۲ مزایا و معایب روش‌های مبتنی بر رویه می‌باشد.

جدول ۲-۳: مزایا و معایب روش‌های مبتنی رویه

معایب	مزایا
۱. تعامل با کاربر (نیاز به تعریف منحنی اولیه) در مدل‌های هندسی و پارامتری ۲. هزینه بالای محاسباتی ۳. شکست در گسترهای بزرگ (مدل هندسی و پارامتری) ۴. حساس به نویز برای مدل‌های سطح تراز	۱. موفق در تصاویر نویزی (مدل‌های هندسی) ۲. دقت بالا ۳. عدم نیاز به آگاهی از توپولوژی ۴. موفق در شکلهای هندسی پیچیده (با گوش، نوک‌های هلالی و انحنای زیاد)

۵-۴-۲ روش‌های تقسیم‌بندی ترکیبی

مشکلات تقسیم‌بندی MRI مغزی جدید در حال ظهور است و روش‌های جدید به طور مداوم مورد بررسی و معرفی قرار می‌گیرند.

از آنجا که انتخاب مناسب‌ترین تکنیک برای یک برنامه کاربردی خاص، یک کار بسیار سخت می‌باشد، ترکیب چندین تکنیک برای

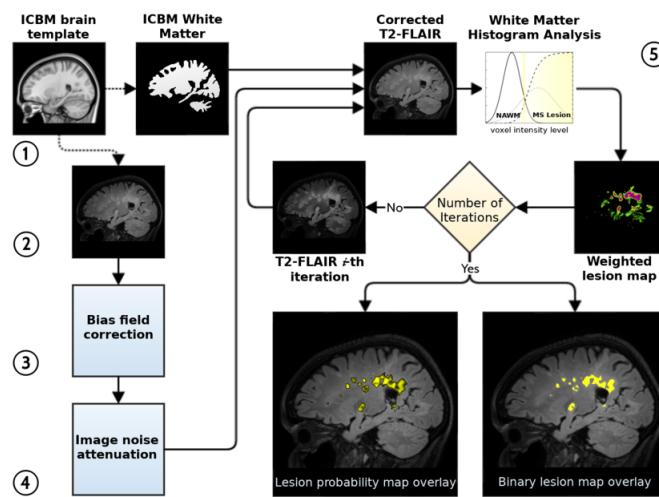
به دست آوردن هدف تقسیم‌بندی ضروری است. بنابراین، روش‌های ترکیبی، طور گسترده در برنامه‌های تقسیم‌بندی MRI مغز

مورد استفاده قرار گرفته است. ایده اصلی این است که روش‌های تقسیم‌بندی مکمل را با یکدیگر ترکیب کرده تا با استفاده از یک

روش تکمیلی از بسیاری از معایب هر یک از روش‌ها جلوگیری کرده و همچنین بتوان به بهبود دقت تقسیم‌بندی بپردازیم [۷].

اشکال اصلی روش‌های ترکیبی تقسیم بنده، اغلب پیچیدگی رویکرد در مقایسه با هر یک از روش‌های استفاده شده افزایش پیدا می‌کند [۷].

در مرجع [۱۶] در سال ۲۰۱۸ یک روش ترکیبی ارایه داده شده است. فلوچارت سیستم پیشنهادی در شکل ۱۸-۲ قابل مشاهده می‌باشد. روش تقسیم‌بندی ضایعه پیشنهاد شده در این مطالعه متکی به مراحل پردازش تصویر زیر می‌باشد:



شکل ۱۸-۲: فلوچارت روش پیشنهادی [۱۶]

تجزیه و تحلیل داده‌ها استفاده شود که در این مقاله از فیلتر AAD^۱ استفاده شده است.

- تقسیم‌بندی ضایعات ماده سفید: با استفاده از ماسک WM، تصویر FLAIR را می‌توان پردازش کرد تا اطلاعات تصویر

را به پس‌زمینه و ضایعات MS محدود کرد. برای این منظور در این مقاله از یک روش ترکیبی استفاده شده است که در

ادامه توضیح داده خواهد شد.

- کاهش نقشه ضایعات: نقشه طبقه‌بندی فازی حاصل از مرحله قبلی به منظور کاهش واکسل‌های اشتباه تخمین زده شده

(مثبت کاذب) به مرحله کاهش نقشه ضایعه منتقل می‌شود.

الگوریتم ترکیبی استفاده شده در این مقاله بدین صورت می‌باشد که به منظور طبقه‌بندی یک شی (ضایعه MS) از پس‌زمینه در

تصاویر FLAIR، باید حداقل تفاوت بین دو بافت موجود در تصویر اثابت شود که این معمولاً در مورد سیگنال ضایعه MS در تصاویر

FLAIR صادق می‌باشد، جایی که سیگنال‌های ضایعات و پس‌زمینه اختلاف معنی‌داری در میزان شدت سیگنال دارند.

با توجه به این فرضیات، رویکرد پیشنهادی شامل دو الگوریتم طبقه‌بند منطقی^۲ و بهبود کنتراست تکراری^۳ استفاده شده است. در

این رویکرد تمرکز اصلی بر روی شدت روشنایی واکسل‌ها می‌باشد بنابراین در تصاویر MS ضایعات FLAIR دارای بیشترین سطح

روشنایی می‌باشند به همین دلیل می‌توان از یک طبقه‌بند منطقی به منظور تشخیص واکسل‌های ضایعه از پس‌زمینه استفاده کرد

که این طبقه‌بند منطقی به صورت رابطه ۷۱-۲ بیان می‌شود.

$$S[I(r)] = \frac{1}{1 + e^{-\frac{I(r)-\beta}{\alpha}}} \quad (70-2)$$

که در آن $I(r)$ شدت روشنایی واکسل‌های تصویر می‌باشد. یکی از ویژگی‌های جالب که می‌تواند در عملکرد اینتابع برجسته شود

این است که امکان به دست آوردن یک طبقه‌بندی فازی، یعنی یک انتقال صاف بین ضایعه و پس‌زمینه بدست آورده که این ویژگی

به طور مستقیم توسط پارامترهای (α, β) مدولاسیون می‌شود. پارامتر α ناحیه انتقال بین بافت ضایعه و پس‌زمینه را مدل‌سازیون

می‌کند هرچه مقدار آن به سمت صفر میل کند تابع مورد نظر به سمت باینری شدن پیش می‌رود. پارامتر β مسئول تغییر منحنی

از طریق محور آستانه می‌باشد، یعنی شدت روشنایی واکسل است.

در این مرحله می‌بایست تابع ۷۱-۲ با داده‌های موجود سازگار شود برای این منظور از آنالیز هیستوگرام WM استفاده شده است.

¹Anisotropic Anomalous Diffusion

²Logistic Classification (LC)

³iterative contrast enhancement (ICE)

مقدار پارامتر β از طریق رابطه بدهت می‌آید.

$$\beta = \frac{(p_{max} - p_{min})}{\gamma} + p_{min} \quad (71-2)$$

که در آن p_{min} و p_{max} به ترتیب بیشترین مقدار موجود در هیستوگرام و اولین تخمین از مقدار آستانه برای جداسازی بافت ضایعه از پس‌زمینه می‌باشد. سپس مقدار α را می‌توان به صورت زیر محاسبه کرد.

$$\begin{aligned} S(p_{min}) &= T = \frac{1}{1 + e^{-\frac{p_{min}-\beta}{\alpha}}} \\ e^{-\frac{p_{min}-\beta}{\alpha}} &= \frac{1-T}{T} \\ \beta - p_{min} &= \ln\left(\frac{1-T}{T}\right) \cdot \alpha \\ \alpha &= \frac{\beta - p_{min}}{\ln\left(\frac{1-T}{T}\right)} \end{aligned} \quad (72-2)$$

در نهایت پس مشخص شدن مقادیر α و β ، رابطه ۷۱-۲ را می‌توان بر روی تصویر FLAIR پیش‌پردازش شده، اعمال کرد که منجر به تقسیم یندی ضایعه می‌شود. با این حال با توجه به پایین بودن کنتراست بین بافت پس‌زمینه و ضایعه، نقشه ضایعه بدهت آمده در تکرار اول بسیار به سمت بافت پس‌زمینه تمایل دارد بنابراین برای رفع این مشکل یک روش تکراری بهبود کنتراست^۱ پیشنهاد شده است که به عملکرد تابع سیگموید کمک می‌کند تا بافت‌های غیر طبیعی را تشخیص دهد.

روش ICE به شدت مربوط به خروجی تابع sigmoid است، که فرض می‌کند بالاترین مقادیر نقوشه ضایعه وزنی در تشخیص ضایعات واقعی MS دیده می‌شود. به عبارت دیگر، روش‌ترین سیگنال در یک تصویر FLAIR تشخیص داده شده دارای احتمال بالاتری از ضایعه MS است بنابراین می‌توان یک روش تکراری را بین تخمین ضایعه و تنظیم کنتراست ضایعه پیشنهاد کرد. این روش تکراری در رابطه ۷۳-۲ نشان داده شده است.

$$I(r)^{i+1} = I(r)^i + \frac{I(r)^i}{1 + e^{-\frac{I(r)-\beta}{\alpha}}} \quad (73-2)$$

این عمل تا زمانی که تعداد تکرار به پایان برسد ادامه پیدا می‌کند در نهایت اخیرین تصویر تولید شده به عنوان نقشه ضایعه در نظر می‌گیرد.

¹Iterative Contrast Enhancement (ICE)

۵-۲ جمع‌بندی

در این فصل مفاهیم پایه در تقسیم‌بندی تصاویر MRI و انواع الگوریتم‌های تقسیم‌بندی و تشخیص ضایعه بیماری MS از روی تصاویر MRI بررسی شد. همانطور که در قبیل نیز بیان شد برای حل مساله تقسیم‌بندی ضایعات MS چهار روش کلی، روش‌های مبتنی بر شدت، روش‌های مبتنی بر اطلس، روش‌های مبتنی بر رویه و روش‌های ترکیبی وجود دارد. هر کدام از این دسته روش‌ها مزایای خود را دارا می‌باشند برای مثال روش‌های مبتنی بر شدت حساس به نویر می‌باشند در حالی که روش‌های مبتنی بر اطلس در مقابل نویر مقاوم می‌باشد. از آنجایی که در چند سال اخر بیشتر تحقیق‌ها بر روی مدل‌های مبتنی بر رویه متمرکز بوده و به دقت بالاتری دست یافته است بنابراین هدف این تحقیق تمرکز بر روی روش‌های مبتنی بر رویه و ارائه متدهای برای تشخیص پلاک‌های بیماری MS است که در فصل‌های آینده ارائه خواهد شد.

منابع و مأخذ

- [1] A. Danelakis, T. Theoharis, and D. A. Verganelakis, “Survey of automated multiple sclerosis lesion segmentation techniques on magnetic resonance imaging,” *Computerized Medical Imaging and Graphics*, vol.70, pp.83–100, 2018.
- [٢] حمید ایرانپور، ”زیست.“ ۲۰۱۵ <http://zistshenasi94.blogfa.com/post/4>
- [3] R. Milo and E. Kahana, “Multiple sclerosis: geoepidemiology, genetics and the environment,” *Autoimmunity reviews*, vol.9, no.5, pp.A387–A394, 2010.
- [4] R. D. Fields, “White matter matters,” *Scientific American*, vol.298, no.3, pp.54–61, 2008.
- [5] X. Lladó, A. Oliver, M. Cabezas, J. Freixenet, J. C. Vilanova, A. Quiles, L. Valls, L. Ramió-Torrentà, and À. Rovira, “Segmentation of multiple sclerosis lesions in brain mri: a review of automated approaches,” *Information Sciences*, vol.186, no.1, pp.164–185, 2012.
- [6] M. Cabezas Grebol *et al.*, “Atlas-based segmentation of multiple sclerosis lesions in magnetic resonance imaging,” 2013.
- [7] I. Despotović, B. Goossens, and W. Philips, “Mri segmentation of the human brain: challenges, methods, and applications,” *Computational and mathematical methods in medicine*, vol.2015, 2015.

- [8] J. G. Sled, A. P. Zijdenbos, and A. C. Evans, “A nonparametric method for automatic correction of intensity nonuniformity in mri data,” *IEEE transactions on medical imaging*, vol.17, no.1, pp.87–97, 1998.
- [9] M. A. Balafar, “Review of intensity inhomogeneity correction methods for brain mri images,” *Issue*, vol.13, pp.60–66, 2012.
- [10] C. Li, J. C. Gore, and C. Davatzikos, “Multiplicative intrinsic component optimization (mico) for mri bias field estimation and tissue segmentation,” *Magnetic resonance imaging*, vol.32, no.7, pp.913–923, 2014.
- [11] A. Birenbaum and H. Greenspan, “Multi-view longitudinal cnn for multiple sclerosis lesion segmentation,” *Engineering Applications of Artificial Intelligence*, vol.65, pp.111–118, 2017.
- [12] O. Ghribi, L. Sellami, M. B. Slima, C. Mhiri, M. Dammak, and A. B. Hamida, “Multiple sclerosis exploration based on automatic mri modalities segmentation approach with advanced volumetric evaluations for essential feature extraction,” *Biomedical Signal Processing and Control*, vol.40, pp.473–487, 2018.
- [13] T. Brosch, L. Y. Tang, Y. Yoo, D. K. Li, A. Traboulsee, and R. Tam, “Deep 3d convolutional encoder networks with shortcuts for multiscale feature integration applied to multiple sclerosis lesion segmentation,” *IEEE transactions on medical imaging*, vol.35, no.5, pp.1229–1239, 2016.
- [14] S. Jain, D. M. Sima, A. Ribbens, M. Cambron, A. Maertens, W. Van Hecke, J. De Mey, F. Barkhof, M. D. Steenwijk, M. Daams, *et al.*, “Automatic segmentation and volumetry of multiple sclerosis brain lesions from mr images,” *NeuroImage: Clinical*, vol.8, pp.367–375, 2015.

- [15] S. Roy, D. Bhattacharyya, S. K. Bandyopadhyay, and T.-H. Kim, “An effective method for computerized prediction and segmentation of multiple sclerosis lesions in brain mri,” *Computer methods and programs in biomedicine*, vol.140, pp.307–320, 2017.
- [16] A. C. da Silva Senra Filho, “A hybrid approach based on logistic classification and iterative contrast enhancement algorithm for hyperintense multiple sclerosis lesion segmentation,” *Medical & biological engineering & computing*, vol.56, no.6, pp.1063–1076, 2018.
- [17] X. Gui, C. Chuansheng, L. Zhong-Lin, and D. Qi, “Brain imaging techniques and their applications in decision-making research,” *Xin li xue bao. Acta psychologica Sinica*, vol.42, no.1, p.120, 2010.
- [18] A. Ceccarelli, R. Bakshi, and M. Neema, “Mri in multiple sclerosis: a review of the current literature,” *Current opinion in neurology*, vol.25, no.4, pp.402–409, 2012.
- [19] I. Dekker and M. P. Wattjes, “Brain and spinal cord mr imaging features in multiple sclerosis and variants,” *Neuroimaging Clinics*, vol.27, no.2, pp.205–227, 2017.
- [20] U. Vovk, F. Pernus, and B. Likar, “A review of methods for correction of intensity inhomogeneity in mri,” *IEEE transactions on medical imaging*, vol.26, no.3, pp.405–421, 2007.
- [21] Z. Hou, “A review on mr image intensity inhomogeneity correction,” *International journal of biomedical imaging*, vol.2006, 2006.
- [22] B. M. Dawant, A. P. Zijdenbos, and R. A. Margolin, “Correction of intensity variations in mr images for computer-aided tissue classification,” *IEEE transactions on medical imaging*, vol.12, no.4, pp.770–781, 1993.

- [23] N. J. Tustison, B. B. Avants, P. A. Cook, Y. Zheng, A. Egan, P. A. Yushkevich, and J. C. Gee, “N4itk: improved n3 bias correction,” *IEEE transactions on medical imaging*, vol.29, no.6, pp.1310–1320, 2010.
- [24] M. J. D. Powell. *Approximation theory and methods*. Cambridge university press, 1981.
- [25] D. García-Lorenzo, S. Francis, S. Narayanan, D. L. Arnold, and D. L. Collins, “Review of automatic segmentation methods of multiple sclerosis white matter lesions on conventional magnetic resonance imaging,” *Medical image analysis*, vol.17, no.1, pp.1–18, 2013.
- [26] S. M. Smith, “Fast robust automated brain extraction,” *Human brain mapping*, vol.17, no.3, pp.143–155, 2002.
- [27] S. H. Gheshlaghi, A. Madani, A. Suratgar, and F. Faraji, “Multiple sclerosis diagnosis with fuzzy cmeans,” *Computer Science & Information Technology*, p.97.
- [28] M. H. Alshayeji, M. A. Al-Rousan, H. Ellethy, and S. Abed, “An efficient multiple sclerosis segmentation and detection system using neural networks,” *Computers & Electrical Engineering*, vol.71, pp.191–205, 2018.
- [29] Y. Zhao, S. Guo, M. Luo, Y. Liu, M. Bilello, and C. Li, “An energy minimization method for ms lesion segmentation from t1-w and flair images,” *Magnetic resonance imaging*, vol.39, pp.1–6, 2017.
- [30] Y. Zhao, S. Guo, M. Luo, X. Shi, M. Bilello, S. Zhang, and C. Li, “A level set method for multiple sclerosis lesion segmentation,” *Magnetic resonance imaging*, vol.49, pp.94–100, 2018.

Abstract

Ferdowsi University Mashhad (FUM)
Department of Computer

Thesis submitted
for the degree of M.Sc.

Title:

MRI Segmentation

Supervisor: DR. Hamid Reza Pour Reza

By: Mehdi Sadeghi Bakhi

January 2018